



دانشگاه ملی مهارت واحد دختران گرگان

پایان نامه کارشناسی پیوسته
رشته مهندسی کامپیوتر

تشخیص احساسات از چهره

استاد راهنما:
کمیل شهواری

نگارش:
مریم طاهری امامی

تیر 1404

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تشکر و قدردانی:

اکنون که به یاری خداوند متعال، گام‌های پایانی مسیر پژوهشی‌ام را پشت سر می‌گذارم، بر خود لازم می‌دانم با تمام فروتنی و امتنان، از استاد فرهیخته و بزرگوار، جناب آقای دکتر کمیل شهواری، که در جایگاه استاد راهنمای پروژه با نگاهی ژرف، راهنمایی‌هایی دلسوزانه و همراهی خردمندانه، مسیر این پژوهش را هموار ساختند، صمیمانه تشکر و قدردانی کنم.

همچنین مراتب سپاس قلبی خود را تقدیم می‌دارم به مدیر محترم گروه، سرکار خانم دکتر منتظری، که با حمایت‌های سازنده، نظارت علمی و مدیریتی ارزشمند، بستری مناسب برای انجام این پروژه فراهم ساختند.

از دیگر اساتید ارجمند، دوستان گرامی و خانواده عزیزم که با محبت، همراهی و دلگرمی‌شان در این مسیر پرفراز و نشیب، یاور من بودند نیز صمیمانه سپاسگزارم. بی‌تردید، ثمره این تلاش، حاصل زنجیره‌ای از مهر، دانش و همراهی است که از دل‌های بزرگی چون شما نشأت گرفته است.

با امید به آن‌که در آینده، بتوانم پاسخ‌گوی اعتماد و محبت شما بزرگواران باشم.

با احترام و ارادت
مریم طاهری امامی

چکیده

این پژوهش به بررسی کارایی شبکه‌های عصبی کانولوشنی (CNN) در شناسایی خودکار احساسات از تصاویر چهره می‌پردازد. باتوجه به اهمیت روزافزون سیستم‌های تشخیص احساسات در کاربردهایی مانند تعامل انسان و ربات، بازاریابی هوشمند و نظارت بر سلامت روان، توسعه روش‌های دقیق در این حوزه ضروری است.

هدف: شناسایی احساسات افراد با کمک تصاویر آنها
روش‌شناسی پژوهش: در این پژوهش یک شبکه عصبی کانولوشنی طراحی و پیاده‌سازی شد و سپس با کمک دیتاست FER-2013 آموزش داده شد. در مرحله بعد خروجی مدل بررسی شد و در چند مرحله مدل بهبود داده شد تا خروجی بهتری ایجاد شود.

یافته‌ها: بعد از چند دور اصلاح مدل، دقت خروجی به بالای 80 درصد رسید که باتوجه به محدودیت‌های سخت افزاری و پردازشی، خروجی مطلوبی بود.

نتیجه‌گیری: شبکه‌های عصبی کانولوشنی اگر به درستی طراحی شوند، با دقت بسیار بالایی قادر به شناسایی احساسات افراد از روی چهره هستند که این شناسایی احساسات در زمینه‌ها و کاربردهای مختلف می‌تواند مورد استفاده قرار بگیرد.

کلیدواژه: یادگیری عمیق، پردازش تصویر، شناسایی خودکار احساسات

فهرست

فصل 1: مقدمه.....	1
1-1- بیان مسئله.....	2
1-2- اهمیت و ضرورت انجام تحقیق.....	3
1-3- مرور پیشینه تحقیق.....	7
1-4- اهداف تحقیق.....	8
1-5- جنبه نوآوری.....	9
1-6- رئوس مطالب سایر فصل‌ها.....	9
فصل 2: هوش مصنوعی و یادگیری عمیق.....	10
2-1- مقدمه.....	11
2-2- هوش مصنوعی.....	11
2-2-1- ویژگی‌های کلیدی هوش مصنوعی:.....	11
2-3- یادگیری.....	11
2-3-1- یادگیری با نظارت (Supervised Learning).....	12
2-3-2- یادگیری بدون نظارت (Unsupervised Learning).....	12
2-3-3- یادگیری تقویتی (Reinforcement Learning - RL).....	13
2-4- شبکه‌های عصبی مصنوعی (Artificial Neural Networks - ANNs).....	13
2-4-1- ساختار پایه یک شبکه عصبی.....	13
2-4-2- انواع شبکه‌های عصبی مصنوعی.....	14
2-4-3- یک شبکه عصبی چگونه یاد می‌گیرد؟.....	14
2-5- یادگیری عمیق.....	15
2-5-1- چرا یادگیری عمیق مهم است؟.....	15
2-5-2- چالش‌های یادگیری عمیق.....	15
2-6- نتیجه‌گیری.....	16
فصل 3: پردازش تصویر و شناسایی احساسات.....	17
3-1- مقدمه.....	18
3-2- پردازش تصویر.....	18
3-3- تشخیص چهره و تشخیص احساسات.....	19
3-4- چالش‌ها و محدودیت‌های مدل‌های پردازش تصویر.....	22
3-5- تکنیک‌های یادگیری عمیق در تشخیص احساسات.....	22
3-5-1- شبکه‌های عصبی کانولوشنی (CNN).....	23
3-5-2- شبکه‌های عصبی بازگشتی (RNN) و LSTM.....	23
3-5-3- شبکه‌های عصبی کانولوشنی - رکورنت (CRNN).....	24
3-5-4- شبکه‌های (Generative Adversarial Networks) GAN.....	25
3-6- چالش‌ها و مزایای یادگیری عمیق در تشخیص احساسات.....	25
3-7- دیتاست‌ها و منابع داده برای تشخیص احساسات چهره.....	26
3-7-1- دیتاست FER-2013.....	27

27	3-7-2- دیتاست+CK
28	3-7-3- دیتاست AffectNet
28	3-7-4- دیتاست EmotionNet
29	3-7-5- دیتاست JAFFE
29	3-7-6- اهمیت تنوع داده‌ها در تشخیص احساسات
30	3-8- الگوریتم‌های مبتنی بر یادگیری عمیق
30	3-8-1- شبکه‌های عصبی کانولوشنی (CNN)
31	3-8-2- الگوریتم (You Only Look Once) YOLO
31	3-8-3- الگوریتم (Single Shot MultiBox Detector) SSD
31	3-8-4- الگوریتم‌های ترکیبی و بهینه‌سازی‌شده
32	3-9- ابزارها و زبان‌های برنامه‌نویسی برای پروژه‌های پردازش تصویر
32	3-9-1- پایتون (Python)
32	3-9-2- سی پلاس پلاس (C++)
33	3-9-3- متلب (MATLAB)
33	3-9-4- جاوا (Java)
34	3-9-5- زبان R
34	3-10- ابزارها و کتابخانه‌ها
34	3-10-1- OpenCV
35	3-10-2- TensorFlow و Keras
35	3-10-3- Pillow
35	3-10-4- Scikit-Image
36	3-10-5- PyTorch
36	3-11- نتیجه‌گیری
37	فصل 4: پیاده‌سازی
38	4-1- مقدمه
38	4-2- مراحل طراحی و پیاده‌سازی پروژه
39	4-2-1- فرایند آموزش و ارزیابی مدل
41	4-2-2- دیتاست استفاده شده در این پروژه
44	4-2-3- پیاده‌سازی الگوریتم CNN برای پردازش تصویر
45	4-3- بررسی داده‌ها
46	4-3-1- تغییر اندازه تصاویر
46	4-3-2- نرمال‌سازی و مقیاس‌دهی (Normalization and Scaling)
47	4-3-3- چرخش و تغییر زاویه تصاویر (Augmentation)
47	4-3-4- شفاف‌سازی (Clearance) و حذف نویز (Noise Removal)
48	4-3-5- برچسب‌گذاری و دسته‌بندی (Labeling and Categorization)
49	4-4- طراحی CNN
49	4-5- آموزش مدل
50	4-5-1- آماده‌سازی داده‌ها
50	4-5-2- نرمال‌سازی داده‌ها
51	4-5-3- تقسیم داده‌ها به مجموعه‌های آموزش و اعتبارسنجی
51	4-5-4- کدگذاری برچسب‌ها (Label Encoding):
51	4-5-5- ایجاد مدل شبکه عصبی کانولوشنی
52	4-5-6- کامپایل مدل
52	4-5-7- آموزش مدل
53	4-5-8- ذخیره مدل

53	4-6- ارزیابی مدل.....
56	4-7- بهینه‌سازی مدل.....
61	4-8- نتیجه‌گیری.....
61	4-9- تحلیل عملکرد مدل یادگیری عمیق.....
65	فصل 5: جمع‌بندی و پیشنهادها.....
66	5-1- نتیجه‌گیری.....
69	5-2- مشکلات و محدودیت‌ها.....
69	5-2-1- مشکلات مربوط به داده‌ها.....
70	5-2-2- مشکلات مربوط به معماری و تنظیمات مدل.....
71	5-2-3- محدودیت‌های منابع محاسباتی.....
71	5-2-4- چالش‌ها در ارزیابی مدل.....
72	5-3- پیشنهادهایی برای کارهای آتی.....
72	5-3-1- بهبود کیفیت داده‌ها.....
73	5-3-2- بهینه‌سازی معماری مدل.....
73	5-3-3- استفاده از تکنیک‌های بهینه‌سازی پیشرفته.....
74	5-3-4- استفاده از تکنیک‌های مقابله با overfitting.....
74	5-3-5- بهبود ارزیابی مدل.....
75	5-3-6- پیشرفت در پیش‌پردازش داده‌ها.....
76	منابع.....

فهرست شکل‌ها

43	 شکل 4-1. زیرنویس شکل
61	 <u>شکل 4-9-1</u>
62	 <u>شکل 4-9-2</u>

فصل 1:

مقدمه

1-1- بیان مسئله

تشخیص احساسات چهره یکی از مهم‌ترین چالش‌های حوزه بینایی ماشین و هوش مصنوعی است که به‌منظور تحلیل و درک احساسات انسانی از تصاویر و ویدئوها استفاده می‌شود. هدف اصلی این پروژه، طراحی و پیاده‌سازی یک سیستم خودکار برای شناسایی و طبقه‌بندی احساسات چهره انسان با استفاده از الگوریتم‌های یادگیری ماشین است. باتوجه‌به رشد سریع تعاملات دیجیتال و آنلاین در دنیای امروز، توانایی شناسایی حالات چهره و احساسات انسانی به ابزاری کلیدی برای بهبود تعاملات انسان - ماشین تبدیل شده است.

تشخیص احساسات چهره یکی از مهم‌ترین و پیچیده‌ترین مسائل در حوزه بینایی ماشین و پردازش تصویر است که در سال‌های اخیر با پیشرفت‌های چشمگیری همراه بوده است. این حوزه به طور خاص به بررسی و شناسایی احساسات انسانی از طریق تحلیل ویژگی‌های صورت پرداخته و می‌تواند کاربردهای فراوانی در زمینه‌های مختلفی مانند روان‌شناسی، بازاریابی، مراقبت‌های بهداشتی، امنیت و حتی تعاملات انسانی با ربات‌ها و سیستم‌های هوش مصنوعی داشته باشد. هدف پروژه حاضر، توسعه یک سیستم هوش مصنوعی برای تشخیص احساسات چهره انسان است که از داده‌های تصویری به‌منظور شناسایی دقیق و مؤثر احساسات استفاده می‌کند.

با استفاده از شبکه‌های عصبی عمیق (Deep Neural Networks) و به‌ویژه شبکه‌های عصبی کانولوشنی (CNNs)، این پروژه به شبیه‌سازی قابلیت‌های انسانی برای تشخیص و تحلیل ویژگی‌های صورت می‌پردازد. شبکه‌های عصبی کانولوشنی به دلیل توانایی بالا در استخراج ویژگی‌های پیچیده از تصاویر، یکی از بهترین گزینه‌ها برای این نوع تحلیل‌ها هستند. هدف از این تحقیق، ایجاد یک مدل هوشمند است که بتواند در محیط‌های مختلف، چه در شرایط نوری خوب و چه در شرایط نوری ضعیف، احساسات مختلف مانند شادی، غم، ترس، عصبانیت، تعجب و نفرت را شناسایی کند.

در روند توسعه این پروژه، داده‌های تصویری از دیتاست‌های معروف مانند FER2013، CK+ و AffectNet مورد استفاده قرار می‌گیرند. این دیتاست‌ها شامل هزاران تصویر چهره با

برچسب‌های مختلف برای احساسات انسانی مانند شادی، غم، ترس، عصبانیت و تعجب هستند. هدف از استفاده از این داده‌ها، آموزش مدل برای شناسایی دقیق این احساسات است. به‌طورکلی، هدف اصلی این پروژه، طراحی و پیاده‌سازی یک مدل تشخیص احساسات چهره است که بتواند بادقت بالا و در شرایط متنوع، احساسات مختلف را از طریق تحلیل ویژگی‌های صورت شبیه‌سازی کرده و در حوزه‌های مختلف کاربرد داشته باشد. این مدل می‌تواند در آینده به‌عنوان یک ابزار قدرتمند در زمینه‌های مختلف تحقیقاتی و صنعتی مورد استفاده قرار گیرد.

1-2- اهمیت و ضرورت انجام تحقیق

در دنیای امروز، تحلیل و شناسایی احساسات انسانی به‌ویژه در موقعیت‌های مختلف اجتماعی و شغلی از اهمیت بسیاری برخوردار است. به‌عنوان مثال، در حوزه بازاریابی، شناخت واکنش‌های احساسی مصرف‌کنندگان می‌تواند به شرکت‌ها کمک کند تا محصولات و خدمات خود را بهتر تطبیق دهند و مشتریان را جذب کنند. در مراقبت‌های بهداشتی، تشخیص احساسات چهره می‌تواند به پزشکان در شناسایی مشکلات روانی یا احساسی بیماران کمک کند. علاوه بر این، در حوزه امنیت و نظارت، این فناوری می‌تواند برای تشخیص رفتارهای مشکوک یا خطرناک مورد استفاده قرار گیرد.

یکی از دلایل اصلی اهمیت این پروژه، کاربردهای آن در بهبود تعاملات انسان و ماشین است. در دنیای مدرن، ربات‌ها و سیستم‌های هوش مصنوعی به‌طور فزاینده‌ای در حال انجام وظایف انسانی هستند. توانایی تشخیص احساسات می‌تواند این سیستم‌ها را انسانی‌تر کند و آنها را قادر سازد تا واکنش‌هایی مطابق با احساسات انسان‌ها نشان دهند. به‌عنوان مثال، در یک سیستم خدمات مشتری خودکار، درک احساسات مشتری از طریق تشخیص چهره می‌تواند به سیستم کمک کند تا واکنش‌های بهتری نسبت به نیازهای مشتری نشان دهد.

یکی از مهم‌ترین کاربردهای تشخیص احساسات چهره در حوزه پزشکی و روان‌شناسی است. بسیاری از اختلالات روانی و عاطفی، از جمله افسردگی، اضطراب و اختلالات شخصیتی، بر

رفتار و احساسات فرد تأثیر می‌گذارند. در چنین شرایطی، تشخیص سریع و دقیق احساسات می‌تواند به روان‌شناسان و پزشکان کمک کند تا مشکلات روانی بیماران را بهتر شناسایی کنند. همچنین، در بیمارانی که قادر به بیان احساسات خود نیستند یا درگیر اختلالات ارتباطی هستند، تشخیص چهره می‌تواند ابزاری مفید برای ارزیابی وضعیت عاطفی آنها باشد. به عنوان مثال، در درمان بیماران مبتلا به بیماری‌های عصبی مانند اوتیسم که قادر به بیان درست احساسات خود نیستند، تحلیل احساسات چهره می‌تواند به تشخیص دقیق‌تر وضعیت روانی و عاطفی آنها کمک کند. این نوع تکنولوژی می‌تواند ابزار مهمی برای معالجه و درمان بیماران در شرایط مختلف باشد.

یکی دیگر از کاربردهای مهم این پروژه در حوزه تعاملات انسان و ربات‌ها است. ربات‌هایی که قادر به تشخیص احساسات چهره انسان هستند، می‌توانند تعاملات طبیعی‌تری با انسان‌ها داشته باشند. این تکنولوژی می‌تواند در ربات‌های خدمت‌رسان یا ربات‌های اجتماعی که به منظور ارائه خدمات به انسان‌ها طراحی شده‌اند، استفاده شود. ربات‌ها می‌توانند با تحلیل احساسات فرد و پاسخ‌دهی به آن، تجربه‌های شبیه به تعاملات انسانی ایجاد کنند. این موضوع به ویژه در زمینه‌های آموزش، مراقبت‌های بهداشتی و خدمات مشتری می‌تواند مفید باشد. برای مثال، ربات‌های مراقبتی که برای افراد سالمند طراحی شده‌اند، می‌توانند با تشخیص احساسات چهره، وضعیت عاطفی فرد را درک کرده و رفتار مناسب‌تری از خود نشان دهند. این امر می‌تواند به بهبود کیفیت زندگی افراد سالمند و ارتقای تجربیات اجتماعی آنها کمک کند.

یکی دیگر از کاربردهای جذاب تشخیص احساسات چهره، در حوزه بازاریابی و تبلیغات است. شرکت‌ها می‌توانند از این فناوری برای تحلیل واکنش‌های احساسی مشتریان نسبت به محصولات یا تبلیغات خود استفاده کنند. تحلیل احساسات چهره در هنگام تماشای تبلیغات یا تجربه محصول می‌تواند به شرکت‌ها کمک کند تا نقاط قوت و ضعف محصولات یا تبلیغات خود را شناسایی کنند و به طور مؤثری آنها را بهبود بخشند. به عنوان مثال، یک شرکت می‌تواند از این تکنولوژی در محیط‌های تحقیقاتی برای ارزیابی واکنش‌های احساسی

مشتریان نسبت به یک محصول جدید استفاده کند. این اطلاعات می‌تواند به طراحان محصول و تبلیغات کمک کند تا محصولاتی با جذابیت بیشتر برای بازار هدف طراحی کنند. تشخیص احساسات چهره همچنین در حوزه امنیت و نظارت نیز کاربرد دارد. این فناوری می‌تواند برای شناسایی رفتارهای مشکوک یا خطرناک از طریق تحلیل حالات چهره افراد در محیط‌های عمومی یا مناطق حساس استفاده شود. به‌ویژه در فرودگاه‌ها، ایستگاه‌های قطار، و مراکز تجاری بزرگ، تشخیص حالات چهره می‌تواند به شناسایی افرادی که رفتارهای غیرمعمولی از خود بروز می‌دهند، کمک کند. به‌عنوان مثال، در یک فرودگاه، سیستم‌های تشخیص احساسات چهره می‌توانند رفتارهای مشکوک افراد را شبیه‌سازی کنند و در صورت مشاهده احساساتی مانند اضطراب شدید یا عصبانیت، به نیروهای امنیتی هشدار دهند. این سیستم‌ها می‌توانند در مقابله با تهدیدات امنیتی و پیشگیری از وقوع حوادث کمک کنند.

تشخیص احساسات چهره می‌تواند در زمینه‌های آموزشی و اجتماعی نیز تأثیرگذار باشد. در آموزش، معلمان می‌توانند از این فناوری برای ارزیابی وضعیت عاطفی دانش‌آموزان استفاده کنند و به‌طور مؤثرتری به آنها کمک کنند. به‌ویژه در مواقعی که دانش‌آموزان در حال مبارزه با مشکلات عاطفی یا روانی هستند، تشخیص احساسات می‌تواند به معلمان در شناسایی نیازهای آموزشی یا عاطفی آنها کمک کند. این فناوری می‌تواند در محیط‌های اجتماعی نیز مفید باشد. به‌عنوان مثال، در رویدادهای گروهی یا جلسات کاری، تشخیص احساسات می‌تواند به مدیران و رهبران تیم کمک کند تا واکنش‌های اعضای تیم را بهتر درک کرده و تصمیمات بهتری اتخاذ کنند. این امر می‌تواند به بهبود تعاملات گروهی و ارتقای عملکرد تیم‌ها کمک کند.

یکی دیگر از کاربردهای بالقوه این پروژه در تجزیه و تحلیل محتوا و رسانه‌ها است. تولیدکنندگان محتوا و رسانه‌ها می‌توانند از تحلیل احساسات چهره در برنامه‌های تلویزیونی، فیلم‌ها و ویدئوهای تبلیغاتی برای ایجاد تجربه‌های جذاب‌تر برای مخاطبان خود استفاده کنند. به‌عنوان مثال، در تولید فیلم‌های سینمایی، این فناوری می‌تواند به شبیه‌سازی واکنش‌های واقعی شخصیت‌ها در برابر

موقعیتهای مختلف کمک کند و کیفیت داستان را بهبود بخشد. این پروژه میتواند به طور گسترده‌ای در تحلیل واکنش‌های بینندگان به محتوای مختلف نیز مورد استفاده قرار گیرد. برای مثال، در پلتفرم‌های استریمینگ ویدئو، تحلیل احساسات چهره کاربران میتواند به تولیدکنندگان محتوا کمک کند تا فیلم‌ها و سریال‌ها را بر اساس واکنش‌های واقعی بینندگان تنظیم کنند.

یکی از چالش‌های عمده‌ای که در این پروژه با آن روبرو خواهیم بود، تنوع زیادی است که در نحوه ابراز احساسات در چهره افراد وجود دارد. به عنوان مثال، افراد با ویژگی‌های صورت متفاوت، احساسات مشابه را به شیوه‌های متفاوتی نمایش می‌دهند. این تفاوت‌ها میتوانند ناشی از جنسیت، سن، فرهنگ و حتی ویژگی‌های فیزیکی صورت باشند. از این رو، توسعه مدلی که قادر به شبیه‌سازی این تنوع‌های فردی و فرهنگی باشد، یکی از اهداف اصلی پروژه است. علاوه بر این، شرایط محیطی و نوری نیز تأثیر زیادی بر دقت تشخیص احساسات دارند.

به عنوان مثال، تشخیص دقیق احساسات در شرایط نوری ضعیف یا زمانی که چهره فرد از زاویه‌های مختلف دیده می‌شود، بسیار چالش‌برانگیز است. در این پروژه، تلاش خواهد شد که مدل به گونه‌ای طراحی شود که حتی در شرایط نوری مختلف یا زوایای متفاوت صورت نیز بتواند به طور دقیق احساسات را شبیه‌سازی کند. استفاده از تکنیک‌های پیشرفته پردازش تصویر و تقویت داده‌ها (Data Augmentation) یکی از روش‌هایی است که در این پروژه برای بهبود دقت سیستم‌ها در این شرایط به کار گرفته می‌شود.

این پروژه به توسعه یک سیستم دقیق و کارآمد برای تشخیص احساسات از چهره می‌پردازد، بلکه هدف دارد تا نشان دهد که چگونه میتوان از این فناوری‌ها در حوزه‌های مختلف علمی و صنعتی استفاده کرد. این پروژه میتواند به عنوان یک گام مؤثر در جهت بهبود تعاملات انسان با ربات‌ها و سیستم‌های هوش مصنوعی، تحلیل رفتارهای اجتماعی، بهبود خدمات به مشتریان و حتی شناسایی مشکلات روانی در افراد استفاده شود.

3-1- مرور پیشینه تحقیق

روند تکامل تکنیک‌های پردازش تصویر و تشخیص چهره در طول چند دهه اخیر تحولات عظیمی را تجربه کرده است. از زمان آغاز استفاده از پردازش تصویر در دهه‌های 1960 و 1970 میلادی، تکنیک‌های ابتدایی برای شناسایی ویژگی‌های اصلی تصویر مورد استفاده قرار می‌گرفتند. یکی از اولین تلاش‌ها در تشخیص چهره، بر اساس الگوریتم‌های هندسی و آماری بود که با استفاده از ویژگی‌های ساده‌ای مانند مرزها، گوشه‌ها و منحنی‌ها، چهره‌ها را شناسایی می‌کردند. این روش‌ها معمولاً با مشکلاتی مانند تغییرات نوری، ابعاد مختلف و موقعیت‌های مختلف چهره مواجه بودند.

در دهه‌های بعد، تحقیقات به سمت استفاده از مدل‌های پیچیده‌تر و جامع‌تر برای تشخیص چهره معطوف شد. یکی از مهم‌ترین پیشرفت‌ها در این زمینه، توسعه مدل‌های آماری بود که توسط روزمبرگ (Rosemberg) و دیگر محققان معرفی شد. این مدل‌ها با استفاده از ویژگی‌های خاص چهره مانند چشم‌ها، بینی و دهان، ساختارهایی را برای شناسایی چهره‌ها طراحی می‌کردند. یکی از مدل‌های مهم این دوره، مدل هار (Cascade Haar) بود که به طور ویژه برای شناسایی چهره‌های انسان طراحی شده بود و به سرعت به یکی از محبوب‌ترین روش‌ها تبدیل شد. با استفاده از ویژگی‌های هار و الگوریتم‌های طبقه‌بندی، توانستند چهره‌ها را با دقت خوبی شناسایی کنند، اما همچنان مشکلاتی مانند دقت پایین در شرایط نوری ضعیف و یا تغییرات زاویه‌ای چهره‌ها وجود داشت.

با آغاز دهه 2000 و ورود شبکه‌های عصبی و یادگیری ماشین به عرصه پردازش تصویر، تحول عظیمی در تشخیص چهره رخ داد. الگوریتم‌های یادگیری ماشین به ویژه الگوریتم‌های SVM (Support Vector Machine) برای تشخیص ویژگی‌های چهره به کار گرفته شدند. این الگوریتم‌ها قادر بودند بر اساس داده‌های آموزشی، ویژگی‌های پیچیده‌تری از چهره‌ها را شناسایی کنند. اما نقطه عطف اصلی در تکامل تکنیک‌های پردازش تصویر و تشخیص چهره، ورود یادگیری عمیق (Deep Learning) به این عرصه بود.

با توسعه و پیشرفت شبکه‌های عصبی پیچشی (CNN) در دهه

2010، تشخیص چهره وارد مرحله جدیدی از دقت و سرعت شد. شبکه‌های عصبی پیچشی به دلیل ساختار خاص خود که قادر به شناسایی ویژگی‌های پیچیده و غیرخطی تصاویر هستند، دقت بالایی در تشخیص چهره‌ها نشان دادند. در این دوره، مدل‌هایی مانند VGG-Face، FaceNet و ResNet به شدت مورد توجه قرار گرفتند. این شبکه‌ها نه تنها قادر به شناسایی چهره‌ها در موقعیت‌های مختلف، بلکه می‌توانند ویژگی‌های دقیق‌تری مانند حالت چهره، سن، جنسیت و حتی احساسات صورت را نیز شناسایی کنند.

در سال‌های اخیر، با توجه به پیشرفت‌های چشمگیر در سخت‌افزارهای پردازشی مانند کارت‌های گرافیکی (GPU) و استفاده از داده‌های عظیم برای آموزش مدل‌ها، توانایی سیستم‌های تشخیص چهره به مراتب افزایش یافته است. این پیشرفت‌ها باعث شده تا سیستم‌های تشخیص چهره به کاربردهای فراوانی در امنیت، پزشکی، صنعت خودروسازی و حتی تحلیل‌های اجتماعی وارد شوند.

در نهایت، روند تکامل این تکنیک‌ها نشان‌دهنده پیشرفت عظیم در زمینه پردازش تصویر و یادگیری ماشین است که همچنان با سرعت بالا در حال تحول است و آینده‌ای پر از امکانات جدید و چالش‌های تازه را در پی خواهد داشت.

4-1- اهداف تحقیق

هدف این تحقیق طراحی و ساخت یک مدل هوش مصنوعی با کمک یادگیری عمیق است که بتواند احساسات افراد را با پردازش تصاویر آنها شناسایی کند. بدین منظور ابتدا یک دیتاست مناسب انتخاب شده، و پیش‌پردازش‌های لازم بر روی آن انجام می‌شود. در این دیتاست باید برچسب‌های مناسب بر اساس احساسات افراد بر روی هر تصویر وجود داشته باشد. سپس یک شبکه عصبی عمیق طراحی می‌شود که قادر به تحلیل تصاویر باشد و با کمک دیتاست آماده شده آموزش می‌بیند. خروجی این مدل بررسی شده و سپس در صورت نیاز ساختار آن بهبود میابد تا کیفیت خروجی بیشتر شود. وقتی کیفیت مدل به حد مطلوبی رسید می‌توان از آن برای شناسایی احساسات در کاربردهای مختلف استفاده کرد.

1-5- جنبه نوآوری

پردازش تصویر و بخصوص شناسایی احساسات، یکی از حوزه‌های نسبتاً جدید در هوش مصنوعی است که کمتر از دو دهه عمر دارد و در سال‌های اخیر باتوجه به افزایش قدرت پردازشی که در دسترس است، به آن توجه بیشتری شده است. تا حدود یک دهه قبل به‌خاطر محدودیت‌های پردازشی، پیاده‌سازی پروژه‌های پردازش تصویر بسیار دشوار و پر هزینه بود. باتوجه به نو بودن این حوزه، انجام پژوهش‌های بیشتر در این حوزه ضروری است.

1-6- رئوس مطالب سایر فصل‌ها

در ادامه این گزارش، ابتدا در فصل دوم، مفاهیم کلی هوش مصنوعی و یادگیری مورد بررسی قرار می‌گیرد. سپس در فصل سوم مباحث مرتبط با پردازش تصویر و شناسایی احساسات چهره شامل معرفی موضوع، الگوریتم‌ها و ابزارها و دیتاست‌ها مورد بحث قرار می‌گیرد. در فصل چهارم پیاده‌سازی پروژه بررسی می‌شود و در نهایت در فصل پنجم جمع‌بندی پروژه ارائه می‌شود.

فصل 2:

هوش مصنوعی و یادگیری عمیق

2-1- مقدمه

در این فصل به بررسی مفهوم هوش مصنوعی و یادگیری پرداخته می‌شود و سپس یادگیری عمیق مورد بررسی قرار می‌گیرد.

2-2- هوش مصنوعی

هوش مصنوعی (AI) شاخه‌ای از علوم کامپیوتر است که به ساخت سیستم‌ها یا ماشین‌هایی می‌پردازد که توانایی انجام وظایفی را دارند که معمولاً به هوش انسانی نیاز دارند. این وظایف شامل یادگیری، استدلال، حل مسئله، درک زبان طبیعی، تشخیص الگوها و تصمیم‌گیری است.

2-2-1- ویژگی‌های کلیدی هوش مصنوعی:

یادگیری (Learning): توانایی بهبود عملکرد بر اساس تجربیات گذشته (مثلاً از طریق داده‌ها).
 استدلال (Reasoning): توانایی تحلیل اطلاعات و رسیدن به نتایج منطقی (مثلاً در بازی شطرنج یا تشخیص پزشکی).
 خود اصلاحی (Self-Correction): قابلیت به‌روزرسانی الگوریتم‌ها برای کاهش خطاها (مانند سیستم‌های پیشنهاد گر Netflix).
 درک محیط (Perception): پردازش داده‌های حسی مانند تصاویر، صداها یا متن‌ها (مثل تشخیص چهره یا دستیارهای صوتی).

2-3- یادگیری

یادگیری در هوش مصنوعی و یادگیری ماشین به روش‌های مختلفی انجام می‌شود که هرکدام برای انواع خاصی از مسائل و داده‌ها مناسب هستند. در اینجا دسته‌بندی اصلی روش‌های یادگیری را بررسی می‌کنیم.

1-3-2- یادگیری با نظارت (Supervised Learning)

مدل با استفاده از داده‌های برچسب‌دار (داده‌هایی که جواب صحیحشان مشخص است) آموزش می‌بینند.

کاربردها:

- طبقه‌بندی (Classification): تشخیص اسپم ایمیل‌ها، تشخیص بیماری از تصاویر پزشکی.
- رگرسیون (Regression): پیش‌بینی قیمت مسکن، پیش‌بینی فروش.

مثال‌ها:

- الگوریتم‌های خطی (مثل رگرسیون خطی).
- درخت تصمیم (Decision Trees).
- شبکه‌های عصبی (در صورت استفاده از داده‌های برچسب‌دار).

2-3-2- یادگیری بدون نظارت (Unsupervised Learning)

مدل از داده‌های بدون برچسب الگوها یا ساختارهای پنهان را کشف می‌کند.

کاربردها:

- خوشه‌بندی (Clustering): تقسیم مشتریان به گروه‌های مشابه.
- کاهش ابعاد (Dimensionality Reduction): فشردن داده‌ها برای نمایش ساده‌تر.

مثال‌ها:

- الگوریتم K-Means برای خوشه‌بندی.
- کاهش ابعاد.

3-2-3- یادگیری تقویتی (Reinforcement Learning - RL)

مدل از طریق تعامل با محیط و دریافت پاداش/تنبیه یاد می‌گیرد (شبیه یادگیری انسان).

کاربردها:

- بازی‌ها
- رباتیک و خودروهای خودران.
- بهینه‌سازی سیستم‌های توصیه‌گر.

4-2- شبکه‌های عصبی مصنوعی (Artificial Neural Networks - ANNs)

شبکه‌های عصبی مصنوعی، مدل‌های محاسباتی الهام‌گرفته از ساختار مغز انسان هستند که برای پردازش اطلاعات پیچیده و یادگیری الگوها از داده‌ها طراحی شده‌اند. این شبکه‌ها از نورون‌های مصنوعی (واحدهای پردازشی) تشکیل می‌شوند که به هم متصل هستند و با تنظیم وزن‌های ارتباطی بین آنها، مدل آموزش می‌بینند.

1-4-2- ساختار پایه یک شبکه عصبی

لایه ورودی (Input Layer): داده‌های خام (مثل پیکسل‌های تصویر یا کلمات متن) به این لایه وارد می‌شوند.

لایه‌های پنهان (Hidden Layers): هر لایه از نورون‌ها و تابع فعال‌سازی (Activation Function) تشکیل شده که محاسبات غیرخطی انجام می‌دهند. عمق شبکه (تعداد لایه‌های پنهان) تعیین‌کننده قدرت یادگیری آن است.

لایه خروجی (Output Layer): نتیجه نهایی (مثل کلاس تصویر یا پیش‌بینی عددی) را تولید می‌کند.

2-4-2- انواع شبکه‌های عصبی مصنوعی

الف. شبکه‌های عصبی پیش‌خور (Feedforward Neural Networks - FNN):

- ساده‌ترین نوع؛ داده فقط در یک جهت (ورودی ← خروجی) جریان می‌یابد.
- کاربرد: پیش‌بینی قیمت‌ها، طبقه‌بندی ساده.

ب. شبکه‌های عصبی کانولوشنی (Convolutional Neural Networks - CNN):

- برای پردازش داده‌های گریدمانند (مثل تصاویر) طراحی شده‌اند.
- از فیلترهای کانولوشنی برای تشخیص ویژگی‌ها (مثل لبه‌ها یا بافت‌ها) استفاده می‌کنند.
- کاربرد: تشخیص چهره، خودروهای خودران.

ج. شبکه‌های عصبی بازگشتی (Recurrent Neural Networks - RNN):

- برای پردازش داده‌های متوالی (مثل متن، صوت، سری‌های زمانی) مناسب هستند.
- دارای حافظه کوتاه‌مدت (اطلاعات از مرحله قبلی به مرحله بعد منتقل می‌شود).
- مشکل: فراموشی گرا دیان در دنباله‌های طولانی.

د. شبکه‌های LSTM و GRU:

- نسخه‌های بهبودیافته RNN برای حل مشکل حافظه بلندمدت.
- کاربرد: ترجمه ماشینی (مثل Google Translate)، پیش‌بینی بورس.

2-4-3- یک شبکه عصبی چگونه یاد می‌گیرد؟

الف. پیش‌روی (Forward Propagation): داده از لایه ورودی به خروجی عبور می‌کند و خروجی محاسبه می‌شود.

ب. محاسبه خطا (Loss Function): تفاوت بین خروجی مدل و جواب واقعی اندازه‌گیری می‌شود (مثل MSE برای رگرسیون).

ج. پسروی خطا (Backpropagation) : خطا به عقب منتشر می‌شود و وزن‌ها با استفاده از بهینه‌سازها تنظیم می‌شوند.

د. تکرار (Epochs) : این فرایند تا رسیدن به دقت مطلوب تکرار می‌شود

2-5- یادگیری عمیق

یادگیری عمیق یک زیرمجموعه تخصصی از یادگیری ماشین است که از شبکه‌های عصبی مصنوعی با چندین لایه پنهان (Deep Neural Networks) برای پردازش داده‌های پیچیده استفاده می‌کند. این روش به دلیل توانایی در یادگیری الگوهای سلسله‌مراتبی و غیرخطی از داده‌های خام (مانند تصاویر، متن یا صوت) بدون نیاز به مهندسی دستی ویژگی‌ها (Feature Engineering) شهرت دارد. چرا این روش "عمیق" نامیده می‌شود؟ زیرا تعداد لایه‌های پنهان (Hidden Layers) در شبکه عصبی زیاد است (از چندین لایه تا صدها لایه).

1-2-5- چرا یادگیری عمیق مهم است؟

- دقت بالا: در بسیاری از مسائل (مثل تشخیص تصویر) از روش‌های سنتی دقیق‌تر عمل می‌کند.
- خودکارسازی استخراج ویژگی: نیازی به تعریف دستی ویژگی‌ها توسط انسان نیست.
- انعطاف‌پذیری: برای انواع داده‌ها (تصویر، متن، صوت) قابل استفاده است.

2-2-5- چالش‌های یادگیری عمیق

- نیاز به داده‌های زیاد: معمولاً به هزاران یا میلیون‌ها نمونه داده نیاز دارد.
- محاسبات سنگین: آموزش مدل‌های عمیق به GPU/TPU و زمان زیاد نیاز دارد.
- عدم شفافیت (Black Box) : تفسیر دلایل تصمیم‌گیری مدل

سخت است.

6-2- نتیجه گیری

در این فصل مفاهیم کلی هوش مصنوعی و یادگیری و همچنین یادگیری عمیق مورد بررسی قرار گرفت. یادگیری عمیق پایه ای برای پردازش تصویر و شناسایی احساسات چهره است که در فصل بعد به تفصیل مورد بحث قرار می گیرد.

فصل 3:

پردازش تصویر و شناسایی احساسات

1-3- مقدمه

در این فصل درباره پردازش تصویر، شناسایی احساسات از روی چهره با کمک پردازش تصویر، ابزارها، الگوریتم‌ها و تکنیک‌ها و همچنین دیتاست‌های مهم توضیحاتی ارائه می‌شود.

2-3- پردازش تصویر

پردازش تصویر یکی از شاخه‌های مهم در علوم کامپیوتر است که به تجزیه و تحلیل تصاویر دیجیتال برای استخراج اطلاعات مفید می‌پردازد. این حوزه شامل مجموعه‌ای از اصول و تکنیک‌هایی است که مراحل مختلفی را برای پردازش و تحلیل تصاویر طی می‌کند.

یکی از مراحل اولیه در پردازش تصویر، پیش‌پردازش است که شامل بهبود کیفیت تصویر از طریق تکنیک‌هایی مانند تنظیم روشنایی، افزایش کنتراست، و حذف نویز می‌باشد. این مرحله به آماده‌سازی تصویر برای مراحل بعدی کمک می‌کند.

در مرحله بعد، استخراج ویژگی‌ها انجام می‌شود. ویژگی‌ها شامل اطلاعاتی مانند لبه‌ها، گوشه‌ها، الگوها، و شکل‌ها هستند که ساختار تصویر را توصیف می‌کنند. تکنیک‌هایی مانند فیلترهای گوسی و (Canny Edge Detection) برای شناسایی این ویژگی‌ها استفاده می‌شوند.

پس از استخراج ویژگی‌ها، تقسیم‌بندی تصویر انجام می‌شود که تصویر را به بخش‌های مختلفی بر اساس شباهت یا تفاوت تقسیم می‌کند. این مرحله برای تشخیص اشیاء یا اجزاء خاص تصویر بسیار حیاتی است.

در نهایت، طبقه‌بندی و تحلیل تصویر بر اساس داده‌های استخراج شده انجام می‌شود. این مرحله از تکنیک‌های یادگیری ماشین و مدل‌های پیشرفته‌تر مانند شبکه‌های عصبی برای شناسایی الگوها و پیش‌بینی نتایج استفاده می‌کند. پردازش تصویر به طور مداوم در حال پیشرفت است و کاربردهای گسترده‌ای در تشخیص چهره، پزشکی، و صنعت دارد.

3-3- تشخیص چهره و تشخیص احساسات

تشخیص چهره یکی از کاربردهای برجسته پردازش تصویر است که در زمینه‌هایی نظیر امنیت، پزشکی، و تعاملات انسانی به کار گرفته می‌شود. این فرایند شامل مراحل مختلفی از جمله پیش‌پردازش تصویر، استخراج ویژگی‌ها، و طبقه‌بندی است. در مرحله پیش‌پردازش، تصویر ورودی به کمک تکنیک‌هایی مانند حذف نویز، تنظیم روشنایی، و افزایش کنتراست بهبود داده می‌شود. سپس، در مرحله استخراج ویژگی‌ها، اطلاعات کلیدی مانند موقعیت چشم‌ها، بینی و دهان با استفاده از الگوریتم‌هایی مانند فیلتر گابور یا تشخیص لبه کنی شناسایی می‌شود.

یکی از تحولات اساسی در این حوزه، استفاده از شبکه‌های عصبی پیچشی (CNN) است. این مدل‌ها با توانایی بالا در شناسایی الگوهای پیچیده، امکان تشخیص چهره‌ها حتی در شرایط دشوار مانند تغییرات نوری، زاویه‌های مختلف، و نویزهای موجود در تصویر را فراهم کرده‌اند. مدل‌های پیشرفته‌ای مانند FaceNet و ResNet توانسته‌اند دقت شناسایی را به سطوح بی‌سابقه‌ای برسانند.

امروزه تشخیص چهره در حوزه‌های متنوعی نظیر سیستم‌های امنیتی، تشخیص احساسات، و حتی بازاریابی مورد استفاده قرار می‌گیرد. با پیشرفت سخت‌افزارهای پردازشی و دسترسی به دیتاست‌های بزرگ، این فناوری به طور مداوم در حال بهبود است و آینده‌ای پر از نوآوری و فرصت‌های تازه برای آن پیش‌بینی می‌شود.

مدل‌های پردازش تصویر در تشخیص احساسات چهره، از مهم‌ترین بخش‌های هر سیستم هوش مصنوعی برای تحلیل و شبیه‌سازی احساسات هستند. این مدل‌ها به‌ویژه در تشخیص تغییرات صورت که نشان‌دهنده حالت‌های عاطفی مختلف است، نقش حیاتی ایفا می‌کنند. چهره انسان یکی از پیچیده‌ترین ویژگی‌های فیزیکی است که می‌تواند تغییرات ظریف در حالت‌های عاطفی را نشان دهد. بنابراین، مدل‌های پردازش تصویر باید قادر باشند این تغییرات را با دقت بالا شبیه‌سازی کنند.

قبل از ظهور شبکه‌های عصبی عمیق و تکنیک‌های یادگیری ماشین، مدل‌های پردازش تصویر بیشتر به صورت سنتی و مبتنی

بر الگوریتم‌های کلاسیک عمل می‌کردند. این الگوریتم‌ها عمدتاً بر روی استخراج ویژگی‌های دستی از تصاویر تمرکز داشتند. برخی از این ویژگی‌ها شامل ویژگی‌های هندسی مانند فاصله بین چشم‌ها، ابروها و دهان، تغییرات شکل صورت و حرکات عضلات صورت بودند.

در این روش‌ها، معمولاً از روش‌های شناسایی ویژگی‌ها مانند LBP (Local Binary Patterns)، Haar-like features و HOG (Histogram of Oriented Gradients) استفاده می‌شد. این ویژگی‌ها به طور مستقیم از تصویر استخراج شده و سپس با استفاده از الگوریتم‌هایی مانند SVM (Support Vector Machine) یا k-NN (k-Nearest Neighbors) طبقه‌بندی می‌شدند. این رویکردها در ابتدا کارایی مناسبی داشتند، اما برای مدل‌هایی که نیاز به پردازش داده‌های پیچیده‌تر و دقیق‌تر دارند، محدودیت‌هایی به وجود می‌آوردند. برای مثال، روش‌های کلاسیک قادر به شبیه‌سازی دقیق‌تر حالت‌های پیچیده عاطفی یا شبیه‌سازی وضعیت‌های پیچیده صورت در محیط‌های مختلف نوری نبودند.

با پیشرفت‌های عظیم در یادگیری عمیق، مدل‌های شبکه‌های عصبی کانولوشنی (CNN) به یکی از بهترین انتخاب‌ها برای پردازش تصویر و شبیه‌سازی احساسات چهره تبدیل شدند. این مدل‌ها به‌ویژه در تشخیص ویژگی‌های مختلف صورت از جمله ابعاد مختلف چشم‌ها، دهان، ابروها و خطوط صورت توانمندی بالایی دارند. شبکه‌های عصبی کانولوشنی قادرند به طور خودکار ویژگی‌های مهم تصویر را بدون نیاز به استخراج ویژگی‌های دستی شبیه‌سازی کنند. این ویژگی‌ها می‌توانند شامل الگوهای پیچیده‌ای باشند که در سطح‌های مختلف ویژگی‌های صورت از قبیل عضلات صورت و حرکات آنها وجود دارند.

یکی از مزایای اصلی شبکه‌های عصبی کانولوشنی این است که قادرند به طور مؤثری از ویژگی‌های محلی تصاویر استفاده کنند. این ویژگی‌ها می‌توانند اطلاعات مهمی در مورد تغییرات وضعیت صورت و احساسات مختلف استخراج کنند. به‌عنوان مثال، در صورت ابراز حالت عصبانیت، تغییرات چشم‌ها و دهان به طور قابل‌توجهی با سایر حالات تفاوت دارند که شبکه‌های عصبی می‌توانند این تغییرات را شبیه‌سازی کنند.

علاوه بر این، شبکه‌های عصبی کانولوشنی قادر به یادگیری

از داده‌های بزرگ و متنوع هستند و این امر موجب افزایش دقت مدل‌ها در تشخیص احساسات می‌شود. مدل‌هایی مانند VGG16، ResNet و Inception از جمله شبکه‌های عصبی کانولوشنی هستند که برای تشخیص احساسات چهره مورد استفاده قرار می‌گیرند و توانسته‌اند نتایج قابل‌توجهی را در این زمینه به دست آورند.

در کنار شبکه‌های عصبی کانولوشنی، شبکه‌های عصبی بازگشتی (RNN) و به‌ویژه مدل‌های LSTM (Long Short-Term Memory) نیز در پردازش تصویر و تشخیص احساسات کاربرد دارند. شبکه‌های RNN قادرند اطلاعات زمانی را پردازش کنند و به‌ویژه در شبیه‌سازی احساسات از ویدئوها و داده‌های زمانی مؤثر باشند. این مدل‌ها قادرند از تغییرات مداوم صورت و وضعیت آن در طول زمان به طور دقیق یاد بگیرند.

در کاربردهایی که نیاز به شبیه‌سازی احساسات در ویدئو یا تسلسل‌های زمانی هستند، شبکه‌های عصبی بازگشتی بسیار مفیدند. به‌عنوان مثال، در تشخیص احساسات در مکالمات یا ویدئوهای تعاملات اجتماعی، این شبکه‌ها قادرند به تغییرات لحظه‌ای در وضعیت صورت و احساسات افراد پاسخ دهند و اطلاعات مربوط به احساسات در حال تغییر را جمع‌آوری کنند.

مدل‌های LSTM به‌ویژه در این زمینه کاربرد دارند زیرا توانایی حفظ اطلاعات طولانی‌مدت را دارند. این ویژگی می‌تواند در تشخیص دقیق‌تر احساسات در طول زمان، به‌ویژه در مواقعی که احساسات به طور تدریجی در طول مکالمه یا ویدئو تغییر می‌کنند، مفید باشد.

در برخی از پروژه‌ها، برای دستیابی به دقت بیشتر، از ترکیب مدل‌های مختلف استفاده می‌شود. به‌عنوان مثال، می‌توان از شبکه‌های عصبی کانولوشنی برای استخراج ویژگی‌های چهره و از شبکه‌های عصبی بازگشتی برای تحلیل داده‌های زمانی استفاده کرد. این ترکیب می‌تواند دقت سیستم‌های تشخیص احساسات را افزایش دهد و مدل‌های ترکیبی قادرند به طور هم‌زمان ویژگی‌های محلی و زمانی را پردازش کنند.

مدل‌های ترکیبی می‌توانند به‌ویژه در شرایطی که نیاز به تجزیه و تحلیل و شبیه‌سازی پیچیده‌تری از احساسات است، مفید باشند. این مدل‌ها می‌توانند اطلاعات و ویژگی‌های

پیچیده‌ای را که در تغییرات صورت و حالات عاطفی در طول زمان وجود دارند، به طور هم‌زمان پردازش کنند.

4-3- چالش‌ها و محدودیت‌های مدل‌های پردازش تصویر

باوجود پیشرفت‌های چشمگیر در این مدل‌ها، هنوز هم چالش‌هایی وجود دارد که باید برطرف شوند. یکی از بزرگترین چالش‌ها در این زمینه، تغییرات در وضعیت صورت است.

چهره‌ها ممکن است تحت‌تأثیر عوامل مختلفی مانند نور، زاویه دید، پوشش صورت مثل عینک یا ماسک و تغییرات طبیعی در حالت صورت قرار گیرند. این مسائل می‌توانند دقت مدل‌های پردازش تصویر را کاهش دهند.

علاوه بر این، مدل‌های پردازش تصویر باید قادر باشند به طور دقیق احساسات مختلف را تشخیص دهند و تفاوت‌های ظریف بین حالت‌های مختلف را شبیه‌سازی کنند. این امر به‌ویژه در شرایطی که فرد به طور عمدی احساسات خود را مخفی می‌کند یا در وضعیت‌هایی که احساسات پیچیده‌ای وجود دارد، چالش‌برانگیز است.

مدل‌های پردازش تصویر در تشخیص احساسات چهره نقش مهمی در توسعه سیستم‌های هوش مصنوعی ایفا می‌کنند. استفاده از شبکه‌های عصبی کانولوشنی، شبکه‌های عصبی بازگشتی و مدل‌های ترکیبی به طور قابل‌توجهی دقت این سیستم‌ها را افزایش داده است.

بااین‌حال، همچنان چالش‌هایی وجود دارد که نیاز به بهبود و توسعه بیشتر در این زمینه دارد. پژوهش‌های آینده می‌توانند به حل این مشکلات پرداخته و مدل‌هایی توسعه دهند که قادر به شبیه‌سازی دقیق‌تر و قابل‌اعتمادتر احساسات چهره در شرایط واقعی باشند.

4-3- تکنیک‌های یادگیری عمیق در تشخیص احساسات

یادگیری عمیق (Deep Learning) یکی از پیشرفته‌ترین و مؤثرترین روش‌ها در تشخیص احساسات چهره است. درگذشته، تشخیص احساسات بیشتر به‌وسیله روش‌های سنتی و استخراج

ویژگی‌های دستی انجام می‌شد، اما با ظهور یادگیری عمیق، این امکان فراهم شد که مدل‌ها به طور خودکار از داده‌ها یاد بگیرند و ویژگی‌های پیچیده‌تری را استخراج کنند. در این بخش به بررسی تکنیک‌های یادگیری عمیق که در تشخیص احساسات چهره کاربرد دارند، پرداخته می‌شود.

3-5-1- شبکه‌های عصبی کانولوشنی (CNN)

شبکه‌های عصبی کانولوشنی (Convolutional Neural Networks - CNN) یکی از برجسته‌ترین تکنیک‌ها در پردازش تصویر و تشخیص احساسات هستند. این شبکه‌ها به‌ویژه برای شبیه‌سازی ویژگی‌های محلی در تصاویر چهره مؤثرند. ساختار شبکه‌های CNN به‌گونه‌ای است که قادرند اطلاعات را در چندین سطح مختلف استخراج کنند. هر لایه در این شبکه‌ها ویژگی‌های پیچیده‌تری از تصویر را شبیه‌سازی می‌کند که می‌تواند شامل جزئیاتی مانند شکل چهره، موقعیت چشم‌ها، دهان و ابروها باشد.

در این شبکه‌ها، فیلترهای کانولوشنی برای شبیه‌سازی ویژگی‌های خاص صورت طراحی می‌شوند. این فیلترها به طور خودکار از داده‌ها یاد می‌گیرند و قادرند ویژگی‌های مهم را استخراج کنند. به‌عنوان مثال، در تشخیص احساساتی مانند خشم یا شادی، ویژگی‌هایی از صورت مانند فشار بر ابروها، باز شدن دهان و دیگر تغییرات چهره به طور خاصی نشان‌دهنده این احساسات هستند که شبکه‌های CNN می‌توانند این تغییرات را شبیه‌سازی کنند.

در مقایسه با روش‌های سنتی، شبکه‌های عصبی کانولوشنی دقت بسیار بالاتری دارند زیرا به طور خودکار ویژگی‌ها را یاد می‌گیرند و نیازی به طراحی دستی ویژگی‌ها نیست. این امر باعث افزایش دقت و کاهش پیچیدگی مدل‌ها می‌شود.

3-5-2- شبکه‌های عصبی بازگشتی (RNN) و LSTM

شبکه‌های عصبی بازگشتی (Recurrent Neural Networks - RNN) و به‌ویژه مدل‌های LSTM (Long Short-Term Memory) در زمینه تشخیص احساسات

از روی داده‌های زمانی مانند ویدئوها کاربرد دارند. این مدل‌ها قادرند تغییرات در احساسات را در طول زمان شبیه‌سازی کنند. به طور مثال، در یک ویدئوی مکالمه، احساسات فرد می‌توانند به طور تدریجی تغییر کنند و شبکه‌های RNN می‌توانند این تغییرات را از لحظه به لحظه پردازش کنند.

شبکه‌های LSTM به‌ویژه برای پردازش داده‌های بلندمدت و حفظ اطلاعات در زمان‌های مختلف مفیدند. این مدل‌ها می‌توانند اطلاعات مهمی که در زمان‌های دورتر از لحظات فعلی اتفاق افتاده‌اند را حفظ کنند. در تشخیص احساسات چهره از روی ویدئو، این ویژگی به مدل‌ها کمک می‌کند که احساسات فرد را در طول مکالمه یا تعاملات پیچیده‌تر شبیه‌سازی کنند.

در واقع، RNN و LSTM برای پردازش اطلاعات زمانی که شامل تغییرات مداوم در وضعیت چهره یا بیان احساسات هستند، بسیار کارآمدند. برای مثال، اگر یک فرد در حال گذراندن لحظات شادی باشد و سپس به حالت غمگینی تغییر کند، شبکه‌های RNN می‌توانند این تغییرات در احساسات را به‌درستی پردازش کرده و پیش‌بینی کنند.

3-5-3- شبکه‌های عصبی کانولوشنی - رکورنت (CRNN)

شبکه‌های عصبی کانولوشنی - رکورنت (CRNN) ترکیبی از شبکه‌های CNN و RNN هستند و به‌ویژه برای پردازش داده‌های ویدئویی و شبیه‌سازی احساسات در آنها مناسب هستند. این مدل‌ها می‌توانند ویژگی‌های محلی تصاویر را که توسط لایه‌های CNN استخراج می‌شود، با داده‌های زمانی که توسط لایه‌های RNN پردازش می‌شود، ترکیب کنند. به این ترتیب، مدل قادر است ویژگی‌های صورت را در طول زمان و در مراحل مختلف شبیه‌سازی کند.

CRNN‌ها به‌ویژه در تشخیص احساسات از روی ویدئوها مفید هستند زیرا این شبکه‌ها قادرند تغییرات در حالات صورت را از یک فریم به فریم دیگر پیگیری کنند و اطلاعات زمانی را نیز تحلیل کنند. این مدل‌ها به طور مشترک قادر به تحلیل ویژگی‌های فیزیکی صورت و تغییرات عاطفی آن در

یک بازه زمانی هستند که در مدل‌های جداگانه CNN یا RNN ممکن است از دقت کمتری برخوردار باشد.

3-5-4- شبکه‌های (Generative Adversarial Networks) GAN

شبکه‌های Generative Adversarial Networks (GANs) نیز به‌ویژه در شبیه‌سازی داده‌ها و ایجاد تصاویر جدید کاربرد دارند. این شبکه‌ها از دو بخش اصلی تشکیل شده‌اند: یک Generator که تلاش می‌کند تصاویر جدیدی ایجاد کند و یک Discriminator که سعی در تمایز بین تصاویر واقعی و تصاویر تولید شده توسط Generator دارد. این رقابت میان دو بخش باعث می‌شود که شبکه به طور مداوم بهبود یابد.

در زمینه تشخیص احساسات، از GAN‌ها می‌توان برای تولید تصاویر چهره با حالات مختلف عاطفی استفاده کرد. این تصاویر می‌توانند به‌عنوان داده‌های اضافی برای آموزش سایر مدل‌های یادگیری عمیق، مانند CNN یا LSTM، به کار روند. به این ترتیب، GAN‌ها می‌توانند کمک کنند تا دیتاست‌های آموزشی بزرگتر و متنوع‌تری برای مدل‌های تشخیص احساسات ایجاد شوند و دقت مدل‌ها در شبیه‌سازی حالات چهره بهبود یابد.

3-6- چالش‌ها و مزایای یادگیری عمیق در تشخیص احساسات

یادگیری عمیق به‌ویژه در شبیه‌سازی احساسات پیچیدگی‌هایی به همراه دارد. یکی از چالش‌های اصلی در این زمینه، نیاز به داده‌های آموزشی زیاد و متنوع است. هر چه مدل‌های یادگیری عمیق آموزش داده شوند و داده‌های بیشتری در اختیار داشته باشند، دقت آنها در تشخیص احساسات بالاتر خواهد بود. به همین دلیل، دسترسی به دیتاست‌های مناسب و غنی از احساسات مختلف چهره اهمیت زیادی دارد. از دیگر چالش‌ها می‌توان به تنوع فرهنگی و فردی در ابراز احساسات اشاره کرد. افراد از فرهنگ‌های مختلف و با ویژگی‌های صورت متفاوت ممکن است احساسات مشابه را به طور متفاوتی ابراز کنند. این تفاوت‌ها می‌توانند مدل‌ها

را دچار اشتباه کنند. به همین دلیل، تحقیقات در زمینه بهبود دقت مدل‌ها با در نظر گرفتن تنوع‌های فرهنگی و فردی یکی از حوزه‌های مهم در یادگیری عمیق به شمار می‌آید. با این حال، مزایای یادگیری عمیق در شبیه‌سازی احساسات چهره قابل توجه است. این روش‌ها قادرند به طور خودکار ویژگی‌ها را استخراج کنند و نیاز به پردازش دستی را کاهش دهند. همچنین، دقت بالاتر و توانایی شبیه‌سازی پیچیدگی‌های بیشتر، این روش‌ها را برای کاربردهای واقعی مانند سیستم‌های تعاملی، درمان‌های روان‌شناختی، تبلیغات و ربات‌ها بسیار مناسب می‌سازد.

یادگیری عمیق به‌ویژه با استفاده از شبکه‌های عصبی کانولوشنی، شبکه‌های عصبی بازگشتی، شبکه‌های GAN و دیگر مدل‌های پیشرفته، توانسته است دقت تشخیص احساسات چهره را به طور قابل توجهی افزایش دهد. هرچند چالش‌هایی مانند نیاز به داده‌های آموزشی گسترده و تنوع در ابراز احساسات وجود دارد، اما این تکنیک‌ها همچنان یکی از پیشرفته‌ترین و مؤثرترین روش‌ها در این زمینه به شمار می‌آیند. در نهایت، تحقیقات بیشتر در این زمینه می‌تواند به بهبود مدل‌ها و افزایش دقت آنها در تشخیص احساسات مختلف کمک کند.

7-3- دیتاست‌ها و منابع داده برای تشخیص احساسات چهره

یکی از مهم‌ترین جنبه‌های توسعه مدل‌های تشخیص احساسات چهره، داشتن داده‌های آموزشی متنوع و باکیفیت است. داده‌های مناسب نه تنها دقت مدل‌ها را افزایش می‌دهند، بلکه به مدل‌ها این امکان را می‌دهند که ویژگی‌های پیچیده‌ای از چهره انسان‌ها را شبیه‌سازی کنند. این داده‌ها می‌توانند شامل تصاویر، ویدئوها و یا حتی داده‌های به دست آمده از تعاملات چهره‌ای واقعی باشند. در این بخش به بررسی دیتاست‌ها و منابع داده‌ای که برای تشخیص احساسات چهره استفاده می‌شوند، پرداخته می‌شود.

3-7-1- دیتاست FER-2013

دیتاست (FER-2013) Facial Expression Recognition 2013 یکی از معروفترین و پرکاربردترین دیتاست‌ها در حوزه تشخیص احساسات چهره است. این دیتاست شامل بیش از 35,000 تصویر چهره است که به 7 دسته اصلی از احساسات تقسیم‌بندی شده‌اند: شادی، غم، ترس، خشم، تعجب، نفرت و بی‌احساس (neutral). تصاویر این دیتاست از وبسایت‌های عمومی استخراج شده‌اند و شامل چهره‌های افرادی با ویژگی‌های متفاوت از نظر سن، جنسیت، نژاد و ویژگی‌های دیگر هستند. این دیتاست به‌ویژه برای آموزش مدل‌های یادگیری ماشین و یادگیری عمیق کاربرد دارد و به‌عنوان یک منبع استاندارد در بسیاری از تحقیقات علمی و پروژه‌های عملی مورد استفاده قرار می‌گیرد. همچنین، به‌خاطر اندازه بزرگ و تنوع بالای تصاویر موجود در آن، FER-2013 قادر است به مدل‌های تشخیص احساسات کمک کند تا ویژگی‌های مختلف صورت انسان‌ها را شبیه‌سازی کرده و حالت‌های مختلف عاطفی را تشخیص دهند.

3-7-2- دیتاست CK+

دیتاست CK+ (Extended Cohn-Kanade) یکی دیگر از منابع مهم داده برای تشخیص احساسات چهره است. این دیتاست شامل ویدئوهایی از چهره‌های انسان در حال ابراز احساسات مختلف است و به دلیل دارا بودن اطلاعات زمانی، می‌تواند به مدل‌های یادگیری عمیق برای تشخیص تغییرات عاطفی در طول زمان کمک کند. CK+ شامل 593 ویدئو از 123 نفر می‌باشد که این ویدئوها به طور خاص تغییرات صورت در هنگام نمایش احساسات مختلف را ثبت کرده‌اند. یکی از ویژگی‌های منحصر به فرد CK+، این است که داده‌ها نه تنها شامل تصاویر ثابت از چهره‌ها بلکه شامل توالی‌های زمانی است که در آن تغییرات حالت صورت در طول زمان ثبت می‌شود. این ویژگی به مدل‌ها این امکان را می‌دهد که تغییرات دقیق‌تر و پیشرفته‌تری در احساسات را تحلیل کنند. در واقع، CK+ بیشتر برای پروژه‌هایی مناسب است

که نیاز به پردازش داده‌های زمانی مانند ویدئوها دارند و می‌تواند در آموزش مدل‌های شبکه عصبی بازگشتی (RNN) یا LSTM که داده‌های زمانی را پردازش می‌کنند، مفید باشد.

3-7-3- دیتاست AffectNet

AffectNet یکی از بزرگترین دیتاست‌های موجود برای تشخیص احساسات چهره است که توسط University of Denver ایجاد شده است. این دیتاست شامل بیش از 1 میلیون تصویر چهره است که به 8 دسته مختلف از احساسات طبقه‌بندی شده‌اند: شادی، غم، ترس، خشم، تعجب، نفرت، بی‌احساس (neutral) و حالت "مشخص نشده". یکی از ویژگی‌های منحصر به فرد AffectNet، تنوع بالای داده‌های آن است، به‌طوری‌که شامل تصاویر از افراد با نژاد، جنسیت و سن‌های مختلف است.

AffectNet برای مدل‌هایی که نیاز به داده‌های بزرگ و متنوع دارند، بسیار مناسب است. این دیتاست به‌ویژه برای شبیه‌سازی دقیق‌تر احساسات در سطح‌های مختلف صورت و در شرایط نوری مختلف می‌تواند مفید باشد. با استفاده از این دیتاست، مدل‌ها قادر خواهند بود به ویژگی‌های پیچیده‌تری از صورت انسان دست یابند و تشخیص بهتری برای احساسات ارائه دهند. این دیتاست همچنین برای آموزش شبکه‌های عصبی کانولوشنی (CNN) که نیاز به داده‌های زیادی برای یادگیری ویژگی‌ها دارند، به‌ویژه برای مدل‌هایی که در شرایط دنیای واقعی قرار دارند، بسیار مناسب است.

3-7-4- دیتاست EmotioNet

دیتاست EmotioNet یکی دیگر از منابع داده بزرگ در تشخیص احساسات است که شامل بیش از 1 میلیون تصویر چهره از کاربران اینترنتی می‌باشد. این دیتاست به‌ویژه به دلیل تنوع زیاد در احساسات و رفتارهای چهره‌ای شناخته می‌شود. تصاویر EmotioNet به 7 دسته اصلی از احساسات شامل شادی،

غم، خشم، ترس، تعجب، نفرت و بیاحساس طبقه‌بندی شده‌اند. یکی از ویژگی‌های خاص این دیتاست، این است که داده‌های آن از منابع مختلفی استخراج شده‌اند که این امر به مدل‌ها این امکان را می‌دهد که احساسات چهره‌ها را در شرایط مختلف و با ویژگی‌های متفاوت شبیه‌سازی کنند. همچنین، EmotioNet می‌تواند به مدل‌ها کمک کند که احساسات پیچیده‌تری مانند خشم یا ترس را با دقت بالاتری شبیه‌سازی کنند. این دیتاست همچنین برای مدل‌های یادگیری عمیق مناسب است که می‌خواهند تغییرات صورت را در شرایط مختلف محیطی شبیه‌سازی کنند.

3-7-5- دیتاست JAFFE

دیتاست JAFFE (Japanese Female Facial Expression) یک دیتاست قدیمی است که برای تشخیص احساسات چهره مورد استفاده قرار می‌گیرد. این دیتاست شامل 213 تصویر از 10 حالت مختلف عاطفی است که توسط 10 زن ژاپنی ابراز شده‌اند. هر تصویر به صورت دقیق بر اساس 6 احساس اصلی (شادی، غم، ترس، خشم، تعجب و بیاحساس) برچسبگذاری شده است. با اینکه دیتاست JAFFE قدیمی است، اما به خاطر سادگی و اندازه مناسب آن، هنوز هم در بسیاری از تحقیقات علمی به ویژه در مطالعات پایه‌ای و آموزش مدل‌های ساده‌تر استفاده می‌شود. این دیتاست می‌تواند برای تست مدل‌های اولیه تشخیص احساسات و همچنین در مواردی که نیاز به شبیه‌سازی احساسات چهره در شرایط کنترل‌شده و محدود وجود دارد، مفید باشد.

3-7-6- اهمیت تنوع داده‌ها در تشخیص احساسات

یکی از مهم‌ترین چالش‌ها در تشخیص احساسات چهره، تنوع فرهنگی و فردی در ابراز احساسات است. چهره افراد در فرهنگ‌ها و مناطق مختلف ممکن است ویژگی‌های متفاوتی در ابراز احساسات داشته باشد. به عنوان مثال، در برخی فرهنگ‌ها ممکن است افراد تمایل کمتری به ابراز احساسات

داشته باشند یا نحوه نمایش آنها متفاوت باشد. از اینرو، استفاده از دیتاست‌هایی با تنوع فرهنگی و فردی بالا اهمیت زیادی دارد.

دیتاست‌هایی مانند AffectNet و EmotioNet که تنوع بالایی دارند، به مدل‌ها این امکان را می‌دهند که احساسات چهره را در شرایط واقعی‌تری شبیه‌سازی کنند و به نتایج دقیق‌تری دست یابند.

دیتاست‌ها و منابع داده برای تشخیص احساسات چهره یکی از ارکان اصلی در آموزش و ارزیابی مدل‌های یادگیری ماشین و یادگیری عمیق هستند. از دیتاست‌های معروف مانند FER، CK+، 2013- و AffectNet گرفته تا دیتاست‌های خاص‌تر مانند EmotioNet، هر کدام ویژگی‌ها و مزایای خاص خود را دارند. استفاده از این داده‌ها به مدل‌ها این امکان را می‌دهد که ویژگی‌های مختلف صورت انسان‌ها را به طور دقیق‌تری شبیه‌سازی کرده و احساسات را در شرایط مختلف به‌خوبی تشخیص دهند.

3-8- الگوریتم‌های مبتنی بر یادگیری عمیق

3-8-1- شبکه‌های عصبی کانولوشنی (CNN)

شبکه‌های عصبی پیچشی (CNN)، یکی از موفق‌ترین روش‌های یادگیری عمیق برای پردازش تصاویر و ویدئوها هستند. این شبکه‌ها توانایی استخراج ویژگی‌های پیچیده را از داده‌های تصویری دارند و در کاربردهایی مانند تشخیص چهره، شناسایی اشیاء و تقسیم‌بندی تصویر به طور گسترده استفاده می‌شوند. مدل‌های پیشرفته مانند VGGNet، ResNet و Inception با دقت بالا و سرعت قابل‌قبول در پردازش داده‌ها عمل می‌کنند. با این حال، یکی از چالش‌های این مدل‌ها، نیاز به منابع محاسباتی قوی است.

3-8-2- الگوریتم YOLO (You Only Look Once)

الگوریتم YOLO یکی از پیشرفته‌ترین روش‌ها برای شناسایی و تشخیص اشیاء در تصاویر و ویدئوها است. این الگوریتم با تقسیم تصویر به چندین شبکه و تحلیل هم‌زمان، قادر است اجسام موجود در تصویر را به سرعت شناسایی کند. YOLO به دلیل سرعت بالا و دقت قابل‌توجه، در کاربردهای زمان واقعی مانند سیستم‌های نظارتی، خودروهای خودران و رباتیک استفاده می‌شود. نسخه‌های جدیدتر این الگوریتم مانند YOLOv5 بهینه‌سازی‌های بیشتری در سرعت و دقت ارائه داده‌اند.

3-8-3- الگوریتم SSD (Single Shot MultiBox Detector)

الگوریتم SSD یکی دیگر از الگوریتم‌های یادگیری عمیق برای شناسایی اشیاء است که به دلیل ساختار ساده‌تر و سرعت بالاتر نسبت به الگوریتم‌های مشابه مانند Faster R-CNN، محبوبیت زیادی پیدا کرده است. این روش به‌ویژه در کاربردهایی که نیاز به سرعت بالا دارند، مانند تحلیل ویدئوهای زنده، مورد استفاده قرار می‌گیرد.

3-8-4- الگوریتم‌های ترکیبی و بهینه‌سازی‌شده

الگوریتم‌های Faster R-CNN.A Faster R-CNN یکی از پیشرفته‌ترین مدل‌های یادگیری عمیق برای شناسایی اشیاء است که ترکیبی از شبکه‌های عصبی پیچشی و منطقه‌های پیشنهادی (Region Proposal Network) را برای شناسایی دقیق‌تر ارائه می‌دهد. این الگوریتم با وجود دقت بالا، به دلیل پیچیدگی محاسباتی، سرعت پایین‌تری نسبت به YOLO و SSD دارد، اما نسخه‌های بهینه‌شده آن برای کاربردهای ویدئویی نیز مناسب هستند.

3-9- ابزارها و زبان‌های برنامه‌نویسی برای پروژه‌های پردازش تصویر

پردازش تصویر یکی از حوزه‌های اصلی در علوم کامپیوتر و هوش مصنوعی است که به طور گسترده در موضوعاتی مانند تشخیص چهره، شناسایی اشیاء، تحلیل تصاویر پزشکی و بسیاری موارد دیگر استفاده می‌شود. انتخاب زبان برنامه‌نویسی و ابزارهای مناسب برای پروژه پردازش تصویر، تأثیر مستقیم بر سرعت توسعه، کارایی و موفقیت پروژه دارد. در این متن به معرفی ابزارها و زبان‌های محبوب پردازش تصویر و مقایسه آنها می‌پردازیم تا بهترین انتخاب برای پروژه‌های مختلف مشخص شود.

3-9-1- پایتون (Python)

پایتون یکی از محبوب‌ترین زبان‌های برنامه‌نویسی برای پردازش تصویر است. ویژگی‌های مهم آن شامل سادگی، خوانایی بالا، و وجود کتابخانه‌های متنوعی مانند OpenCV، TensorFlow و Scikit-Image است. مزایا:

- کتابخانه‌های قدرتمند TensorFlow، Keras، OpenCV، PyTorch، و از جمله کتابخانه‌های محبوب پایتون هستند که برای پردازش تصویر بهینه‌سازی شده‌اند.
- اکوسیستم گسترده: به دلیل استفاده گسترده از پایتون در یادگیری ماشین و هوش مصنوعی، ابزارها و منابع آموزشی زیادی برای یادگیری آن وجود دارد.
- انعطاف‌پذیری: مناسب برای پروژه‌های تحقیقاتی و صنعتی. معایب:
- سرعت کمتر نسبت به زبان‌های سطح پایین‌تر مانند C++.

3-9-2- سی پلاس پلاس (C++)

زبان C++ یک زبان قدرتمند با کارایی بالا است که در پروژه‌های پردازش تصویر، به‌ویژه در کاربردهایی که نیاز

به سرعت بالا دارند، استفاده می‌شود OpenCV. ابتدا در ++C توسعه یافت و این زبان هنوز هم در بسیاری از پروژه‌های صنعتی استفاده می‌شود.

مزایا:

- سرعت بالا: مناسب برای پردازش بلادرنگ و سیستم‌های تعبیه شده.
- دسترسی به سخت‌افزار: امکان استفاده بهینه از پردازنده‌ها و کارت‌های گرافیکی.
- استفاده در محیط‌های صنعتی: معمولاً در پروژه‌های رباتیک و خودروهای خودران استفاده می‌شود.
- معایب:
- پیچیدگی و زمان‌بر بودن کدنویسی.
- یادگیری سخت‌تر نسبت به پایتون.

3-9-3- متلب (MATLAB)

MATLAB یک ابزار قوی برای پردازش تصویر و پردازش سیگنال است. این زبان بیشتر در دانشگاه‌ها و مراکز تحقیقاتی استفاده می‌شود.

مزایا:

- محیط توسعه یکپارچه: ابزارهای بصری برای آزمایش سریع الگوریتم‌ها.
- کتابخانه‌های تخصصی: شامل کتابخانه‌های آماده برای پردازش تصویر.
- معایب:
- هزینه بالا.
- مناسب نبودن برای پیاده‌سازی‌های عملی در مقیاس بزرگ.

3-9-4- جاوا (Java)

جاوا به دلیل قابلیت‌های میان پلتفرمی و پایداری بالا در پروژه‌های پردازش تصویر مورد استفاده قرار می‌گیرد.

مزایا:

- پایداری و امنیت: مناسب برای سیستم‌های پیچیده و قابل اطمینان.
- کتابخانه‌های موجود: ابزارهایی مانند JavaCV و ImageJ. معایب:
- سرعت کمتر نسبت به C++ و پیچیدگی بیشتر در کدنویسی پردازش تصویر نسبت به پایتون.

3-9-5- زبان R

- زبان R زبان تخصصی تحلیل داده‌ها و آمار است که در پردازش تصویر کمتر از زبان‌های دیگر استفاده می‌شود. مزایا:
- مناسب برای تحلیل داده‌های تصویری در کنار داده‌های آماری.
 - معایب:
 - عدم تطبیق با پروژه‌های زمان واقعی.

3-10- ابزارها و کتابخانه‌ها

3-10-1- OpenCV

- OpenCV یکی از کتابخانه‌های اصلی پردازش تصویر است که در زبان‌های مختلف از جمله Python و C++ قابل استفاده است. این کتابخانه قابلیت‌های مختلفی مانند تشخیص لبه، شناسایی اشیاء و تحلیل ویدئو را فراهم می‌کند. مزایا:
- رایگان و متن‌باز.
 - سازگاری با پایتون و C++.
 - مناسب برای پروژه‌های تحقیقاتی و صنعتی.
 - معایب:
 - یادگیری ابزارهای پیشرفته آن زمان‌بر است.

TensorFlow و Keras -3-10-2

این دو ابزار عمدتاً برای یادگیری عمیق استفاده می‌شوند و در کاربردهایی مانند شناسایی چهره و طبقه‌بندی تصاویر بسیار قوی هستند.

مزایا:

- پشتیبانی از مدل‌های یادگیری عمیق: امکان استفاده از CNN و دیگر شبکه‌های پیچیده.
- پشتیبانی از GPU: سرعت بالا در پردازش داده‌های حجیم.
- معایب:
- نیاز به منابع محاسباتی قدرتمند.

Pillow -3-10-3

کتابخانه‌ای ساده و سبک برای پردازش تصویر در پایتون است.

مزایا:

- مناسب برای پروژه‌های کوچک و مبتدی.
- کاربری آسان.
- معایب:
- امکانات محدود در مقایسه با OpenCV

Scikit-Image -3-10-4

Scikit-Image یک ابزار دیگر در پایتون است که بر اساس کتابخانه SciPy ساخته شده و برای تحلیل تصاویر علمی استفاده می‌شود.

مزایا:

- سادگی: مناسب برای کاربردهای آکادمیک.
- کتابخانه‌های قوی: برای فیلترها و الگوریتم‌های مختلف.

معایب:

- محدودیت در قابلیت‌های پیشرفته.

PyTorch -3-10-5

PyTorch یکی دیگر از ابزارهای یادگیری عمیق است که به دلیل انعطافپذیری و سهولت در طراحی مدلها در پروژههای پردازش تصویر محبوبیت زیادی دارد.

مزایا:

- طراحی ساده و تعاملی.

- سرعت بالا.

معایب:

- نسبت به TensorFlow جامعه کاربری کوچکتری دارد.

3-11- نتیجه گیری

در این فصل ابزارها، تکنیکها، کتابخانهها و دیتاستهای مهم در پردازش تصویر و شناسایی احساسات مورد بررسی قرار گرفت. برای پیاده سازی این پروژه بعد از بررسی کامل موارد گفته شده، الگوریتم، زبان برنامه نویسی، کتابخانه، تکنیکها و دیتاست مناسب انتخاب گردید که شرح پیاده سازی آن در فصل بعد خواهد آمد.

فصل 4:

پیاده‌سازی

4-1- مقدمه

در این پروژه، هدف اصلی تشخیص و شبیه‌سازی احساسات مختلف انسان‌ها بر اساس ویژگی‌های چهره است. برای رسیدن به این هدف، رویکرد تحقیقاتی ما ترکیبی از تحلیل داده‌ها و مدل‌سازی یادگیری عمیق است. در این قسمت، روش کلی تحقیق به طور دقیق‌تر توضیح داده خواهد شد و تصمیمات کلیدی که در طول فرایند تحقیق اتخاذ شده‌اند، روشن خواهد شد.

4-2- مراحل طراحی و پیاده‌سازی پروژه

روش تحقیق اصلی که در این پروژه انتخاب شده است، مدل‌سازی با استفاده از الگوریتم‌های یادگیری ماشین و یادگیری عمیق است. در این رویکرد، هدف این است که با استفاده از مجموعه‌ای از داده‌های آموزشی تصاویر چهره و برچسب‌های مربوط به احساسات مختلف، مدل‌هایی بسازیم که قادر به شناسایی و تشخیص احساسات انسان‌ها از روی ویژگی‌های چهره‌شان باشند.

مدل‌سازی در این پروژه عمدتاً بر پایه استفاده از شبکه‌های عصبی کانولوشنی (CNN) و دیگر تکنیک‌های یادگیری عمیق قرار دارد. شبکه‌های عصبی کانولوشنی به دلیل قدرت بالای خود در پردازش داده‌های تصویری و استخراج ویژگی‌های پیچیده از تصاویر، یکی از بهترین انتخاب‌ها برای این نوع پروژه‌ها به شمار می‌روند. شبکه‌های CNN با استفاده از لایه‌های مختلف خود می‌توانند ویژگی‌های سطح پایین مانند لبه‌ها و بافت‌ها را شناسایی کرده و سپس آنها را به ویژگی‌های سطح بالاتر مانند ویژگی‌های احساسی چهره تبدیل کنند.

1-2-4- فرایند آموزش و ارزیابی مدل

در این پروژه، داده‌های مربوط به تصاویر چهره‌ها به‌عنوان ورودی به شبکه عصبی وارد می‌شوند و مدل ما به‌صورت خودکار ویژگی‌های مختلف صورت را شبیه‌سازی و تحلیل می‌کند. برای این منظور، از تکنیک‌های پیش‌پردازش تصویر مانند تغییر اندازه تصاویر (resizing)، نرمال‌سازی (normalization) و استخراج ویژگی‌ها استفاده می‌شود تا داده‌های ورودی برای مدل قابل‌استفاده و بهینه شوند.

پس از آماده‌سازی داده‌ها، مدل آموزش می‌بیند. فرایند آموزش مدل به طور عمده شامل استفاده از تکنیک‌های یادگیری نظارت شده است. در این نوع یادگیری، هر تصویر چهره دارای یک برچسب است که نشان‌دهنده احساس موجود در آن تصویر است. این احساسات شامل شادابی، غم، ترس، خشم، تعجب، نفرت و بی‌احساس است. هدف مدل این است که با استفاده از این داده‌های آموزشی، ویژگی‌های مختلف چهره را شبیه‌سازی کرده و احساسات مختلف را از یکدیگر تمییز دهد.

برای ارزیابی مدل، از مجموعه داده‌های تست جداگانه استفاده می‌شود. این داده‌ها برای ارزیابی نهایی مدل و بررسی دقت آن به کار می‌روند. معیارهایی مانند دقت (accuracy)، دقت پیش‌بینی (precision)، بازیابی (recall) و F1-score برای اندازه‌گیری عملکرد مدل استفاده می‌شوند. این معیارها به ما کمک می‌کنند تا کیفیت پیش‌بینی‌های مدل را ارزیابی کنیم و مطمئن شویم که مدل قادر است به‌درستی احساسات مختلف را شناسایی کند.

در این پروژه، روش‌های انتخاب‌شده برای تحلیل و شبیه‌سازی احساسات چهره انسان‌ها، مبتنی بر یادگیری عمیق و استفاده از شبکه‌های عصبی کانولوشنی (CNN) هستند. این انتخاب‌ها به دلیل قدرت بالای این مدل‌ها در پردازش داده‌های تصویری و استخراج ویژگی‌های پیچیده از تصاویر صورت‌گرفته است. در ادامه، دلایل انتخاب این روش‌ها را به طور تفصیل توضیح می‌دهیم:

الف. قدرت بالای شبکه‌های عصبی کانولوشنی در پردازش تصاویر

شبکه‌های عصبی کانولوشنی به طور خاص برای پردازش

داده‌های تصویری طراحی شده‌اند و توانایی بالایی در شبیه‌سازی ویژگی‌های مختلف تصاویر دارند. این مدل‌ها با استفاده از لایه‌های کانولوشنی می‌توانند ویژگی‌های سطح پایین مانند لبه‌ها، بافت‌ها و رنگ‌ها را شبیه‌سازی کرده و این ویژگی‌ها را به ویژگی‌های سطح بالاتر مانند اجزای صورت و احساسات تبدیل کنند. در پروژه‌ای که هدف آن شبیه‌سازی احساسات از روی تصاویر چهره است، استفاده از CNN به عنوان یک مدل پایه‌ای و قدرتمند کاملاً مناسب است، چرا که این مدل می‌تواند به طور خودکار ویژگی‌های مختلف چهره انسان‌ها را استخراج کرده و برای تشخیص احساسات مختلف از آنها استفاده کند.

ب. قابلیت یادگیری مدل از داده‌های حجیم و پیچیده یکی از ویژگی‌های بارز شبکه‌های عصبی، توانایی آنها در یادگیری از داده‌های حجیم و پیچیده است. داده‌هایی که در پروژه شما استفاده می‌شوند، تصاویر چهره افراد با احساسات مختلف هستند که به طور ذاتی پیچیدگی زیادی دارند. شبکه‌های عصبی کانولوشنی با استفاده از لایه‌های مختلف، می‌توانند این پیچیدگی‌ها را یاد بگیرند و به مدل کمک کنند تا تفاوت‌های ظریف میان احساسات مختلف را تشخیص دهد. برای مثال، یک مدل CNN می‌تواند به راحتی تفاوت بین چهره‌ای که شاد است و چهره‌ای که عصبی است را شبیه‌سازی کند، حتی اگر این احساسات در شرایط نوری متفاوت یا با ویژگی‌های چهره‌های مختلف نمایش داده شوند.

ج. قابلیت عمومی‌سازی مدل‌ها برای داده‌های جدید یکی از مشکلات اصلی در پروژه‌هایی که به پردازش تصاویر می‌پردازند، مشکلات مربوط به تعمیم یا عمومی‌سازی مدل‌ها به داده‌های جدید است. شبکه‌های عصبی کانولوشنی به‌ویژه وقتی با تکنیک‌هایی مانند Dropout یا Regularization ترکیب شوند، قادرند به‌خوبی از داده‌های جدید و ناشناخته یاد بگیرند و به طور دقیق عمل کنند. این ویژگی در پروژه‌ای که هدف آن شبیه‌سازی احساسات در چهره‌ها از داده‌های مختلف است، بسیار مهم است، چرا که ممکن است چهره‌ها از فرهنگ‌ها و شرایط مختلف وارد مدل شوند و نیاز به تعمیم مناسب داشته باشند.

د. کارایی بالا و قابلیت پردازش در زمان معقول روش‌های یادگیری عمیق، به‌ویژه شبکه‌های عصبی کانولوشنی،

در مقایسه با روش‌های سنتی تحلیل تصاویر مانند الگوریتم‌های مبتنی بر ویژگی‌های دستی، به طور قابل‌توجهی کاراتر و سریع‌تر عمل می‌کنند. این روش‌ها به دلیل استفاده از تکنیک‌های بهینه‌سازی و موازی‌سازی، می‌توانند مدل‌های پیچیده را در زمان معقولی آموزش دهند و پردازش کنند. در پروژه‌هایی که نیاز به تحلیل حجم زیادی از داده‌ها دارند، این ویژگی‌ها اهمیت زیادی دارند.

ه. موفقیت‌های پیشین در تحقیقات مشابه یکی از دلایل اصلی انتخاب شبکه‌های عصبی کانولوشنی، موفقیت‌های گسترده آنها در پروژه‌های مشابه است. تحقیقات متعددی در زمینه تشخیص احساسات از روی تصاویر چهره، استفاده از CNN را به عنوان یکی از موفق‌ترین روش‌ها معرفی کرده‌اند. به‌ویژه در مواردی که داده‌های تصویری دارای پیچیدگی و تنوع زیادی هستند، این مدل‌ها قادرند عملکرد بسیار خوبی داشته باشند.

روش‌های یادگیری عمیق به‌ویژه استفاده از شبکه‌های عصبی کانولوشنی، به دلیل توانایی بالا در پردازش داده‌های پیچیده تصویری، یادگیری ویژگی‌های چهره و تشخیص احساسات، و همچنین قدرت تعمیم و سرعت بالای پردازش، برای این پروژه انتخاب مناسبی هستند. این روش‌ها علاوه بر تطابق با نیازهای پروژه، نتایج دقیقی در شبیه‌سازی احساسات از تصاویر چهره به دست خواهند داد.

2-2-4- دیتاست استفاده شده در این پروژه

در این پروژه از دیتاست FER-2013 برای آموزش و ارزیابی مدل شبیه‌سازی احساسات چهره استفاده شده است. این دیتاست یکی از مشهورترین و کاربردی‌ترین مجموعه‌داده‌ها در زمینه شناسایی احساسات از تصاویر چهره است و برای آموزش مدل‌های یادگیری ماشین و یادگیری عمیق در این حوزه بسیار مناسب است.

دیتاست FER-2013 یک مجموعه‌داده تصویری است که به‌ویژه برای شناسایی احساسات مختلف انسان‌ها از روی تصاویر چهره طراحی شده است. این دیتاست در مسابقه شناسایی احساسات در صورت چهره که در کنفرانس "ICML 2013" برگزار

شد، ارائه شد. FER-2013 شامل بیش از 35,000 تصویر چهره است که در 7 دسته‌بندی احساسات مختلف قرار دارند. این احساسات عبارت‌اند از:

- شاد
- غمگین
- ترس
- خشم
- تعجب
- نفرت
- بدون احساس (neutral)

این تصاویر به طور دستی برچسب‌گذاری شده‌اند و هر تصویر دارای یک برچسب مربوط به احساسات خاصی است که از چهره فرد استخراج شده است. تصاویر موجود در این دیتاست دارای شرایط نوری، زوایای مختلف صورت و ویژگی‌های چهره متفاوت هستند که باعث می‌شود مدل‌های یادگیری عمیق با چالش‌های واقعی مواجه شوند.

دیتاست FER-2013 از تصاویر چهره سیاه‌وسفید با اندازه $48 * 48$ پیکسل تشکیل شده است. این تصاویر به طور خاص برای شبیه‌سازی احساسات چهره انتخاب شده‌اند و تمامی تصاویر چهره در حالت‌های مختلف احساسی از نزدیک گرفته شده‌اند. ویژگی‌های کلیدی این دیتاست عبارتند از:

1. تعداد تصاویر: دیتاست FER-2013 بیش از 35,000 تصویر را شامل می‌شود که به

7 دسته احساسات مختلف تقسیم می‌شوند. این تنوع بالا در تعداد تصاویر و دسته‌ها، به مدل این امکان را می‌دهد که ویژگی‌های مختلف چهره را به طور دقیق‌تری یاد بگیرد.

2. تنوع در شرایط نوری و چهره‌ها: این دیتاست شامل تصاویر با نورپردازی متفاوت و حالت‌های مختلف صورت است، که به مدل کمک می‌کند تا بتواند احساسات را در شرایط و وضعیت‌های مختلف تشخیص دهد.

3. حجم زیاد داده‌ها: حجم بالای داده‌های موجود در این دیتاست باعث می‌شود که مدل‌های یادگیری عمیق بتوانند با استفاده از این داده‌ها، یادگیری بهتری داشته باشند. داده‌های بزرگتر معمولاً کمک می‌کنند تا مدل‌ها توانایی بیشتری در تعمیم و شبیه‌سازی داشته باشند.

4. دسته‌بندی احساسات: هر تصویر به یکی از 7 احساس اصلی (شاد، غمگین، ترس، خشم، تعجب، نفرت، بیاحساس) برچسبگذاری شده است که این دسته‌بندیها کمک می‌کند تا مدل احساسات مختلف را به طور دقیق از یکدیگر تمییز دهد.

انتخاب دیتاست FER-2013 به دلیل ویژگی‌های خاص آن، به‌ویژه تنوع بالا در دسته‌بندی احساسات و تصاویر مختلف با کیفیت‌های متفاوت، بسیار مناسب برای این پروژه است. این دیتاست به‌خوبی توانایی شبیه‌سازی احساسات را از چهره انسان‌ها ارائه می‌دهد و به‌عنوان یک معیار استاندارد در تحقیقات و پروژه‌های مرتبط با شناسایی احساسات از چهره استفاده می‌شود. علاوه بر این، چون این دیتاست به طور گسترده در تحقیقات مختلف استفاده شده است، مقایسه نتایج مدل‌های مختلف با یکدیگر راحت‌تر و قابل‌فهم‌تر خواهد بود.

استفاده از دیتاست FER-2013 در این پروژه به دلیل تنوع بالای داده‌ها و دسته‌بندی‌های متعدد احساسات، ابزاری قوی برای آموزش و ارزیابی مدل‌های شبیه‌سازی احساسات چهره فراهم می‌آورد. این دیتاست به مدل‌های یادگیری عمیق کمک می‌کند تا ویژگی‌های پیچیده‌ای مانند حالات چهره، حالت‌های احساسی و تغییرات چهره در شرایط مختلف را به طور دقیق یاد بگیرند و برای شبیه‌سازی احساسات به کار روند.



شکل 4-1. نمونه‌ای از داده‌ها

4-2-3- پیاده‌سازی الگوریتم CNN برای پردازش تصویر

شبکه‌های عصبی پیچشی (Convolutional Neural Networks - CNN) یکی از موفق‌ترین مدل‌های یادگیری عمیق هستند که به طور خاص برای پردازش و تحلیل داده‌های تصویری طراحی شده‌اند. این مدل‌ها قادرند ویژگی‌های پیچیده و غیرخطی تصاویر را به طور خودکار استخراج کرده و به‌کارگیری آنها را در تشخیص و طبقه‌بندی تصاویر بهبود دهند. در این مقاله به نحوه پیاده‌سازی یک مدل CNN برای پردازش تصویر می‌پردازیم و مراحل مختلف پیاده‌سازی آن را تشریح خواهیم کرد.

شبکه‌های عصبی پیچشی به طور عمده از سه بخش اصلی تشکیل شده‌اند:

- لایه‌های پیچشی: (Convolutional Layers) این لایه‌ها برای استخراج ویژگی‌های مهم از تصویر مورداستفاده قرار می‌گیرند. در این لایه‌ها، فیلترها یا کرنل‌ها بر روی تصویر اعمال می‌شوند تا ویژگی‌های مختلفی مانند لبه‌ها، گوشه‌ها و بافت‌ها را شناسایی کنند.
- لایه‌های جمع‌وجور: (Pooling Layers) این لایه‌ها مسئول کاهش ابعاد داده‌های استخراج‌شده هستند. معمولاً از روش‌هایی مانند ماکسیمم پولینگ Max Pooling یا متوسط پولینگ (Average Pooling) برای کاهش ابعاد تصویر و حفظ ویژگی‌های مهم استفاده می‌شود.
- لایه‌های کاملاً متصل: (Fully Connected Layers) در این لایه‌ها، ویژگی‌های استخراج‌شده از لایه‌های پیچشی و پولینگ به یک فضای ابعادی مسطح تبدیل شده و به وسیله لایه‌های کاملاً متصل به طور نهایی طبقه‌بندی می‌شوند.

4-3- بررسی داده‌ها

قبل از شروع به پیاده‌سازی مدل CNN، نیاز است که داده‌های تصویری آماده شوند. این مرحله شامل بارگذاری داده‌ها، پیش‌پردازش آنها و تقسیم داده‌ها به مجموعه‌های آموزشی و آزمون است. در ابتدا، تصاویر باید به اندازه مناسب تغییر اندازه داده شوند. به طور معمول، تصاویر به یک اندازه ثابت مانند 224×224 یا 256×256 پیکسل تغییر اندازه داده می‌شوند. سپس تصاویر به مقیاس خاکستری یا RGB تبدیل شده و هر تصویر به یک آرایه از مقادیر پیکسل تبدیل می‌شود.

- در مرحله بعد، داده‌ها به دو مجموعه تقسیم می‌شوند:
- مجموعه آموزشی: برای آموزش مدل استفاده می‌شود.
 - مجموعه آزمایشی: برای ارزیابی عملکرد مدل پس از آموزش استفاده می‌شود.

برای جلوگیری از overfitting آموزش بیش از حد مدل به داده‌های آموزشی داده‌ها معمولاً با تکنیک‌هایی مانند داده‌افزایی (data augmentation) افزایش می‌یابند.

در این پروژه، پیش‌پردازش داده‌ها بخش بسیار مهمی از فرایند تحلیل و یادگیری است. هدف از پیش‌پردازش داده‌ها، آماده‌سازی آنها برای ورودی به مدل‌های یادگیری ماشین و یادگیری عمیق است. به دلیل ویژگی‌های خاص داده‌های تصویری و نیاز به پردازش‌های اولیه برای بهبود عملکرد مدل، مراحل مختلف پیش‌پردازش اعمال شد تا داده‌ها به شکل مناسب برای آموزش و ارزیابی مدل‌های شبیه‌سازی احساسات آماده شوند.

1-3-4- تغییر اندازه تصاویر

اولین و مهم‌ترین مرحله در پیش‌پردازش داده‌ها، تغییر اندازه تصاویر است. تصاویر موجود در دیتاست FER-2013 به طور پیش‌فرض دارای ابعاد 48×48 پیکسل هستند. با این حال، در برخی از پروژه‌ها ممکن است نیاز به تغییر ابعاد برای استفاده بهینه از منابع و سرعت پردازش وجود داشته باشد. برای این پروژه، تصاویر به ابعاد 48×48 پیکسل نگه داشته شدند زیرا این اندازه از قبل استاندارد است و می‌تواند تمام ویژگی‌های لازم برای شبیه‌سازی احساسات را در خود جای دهد. تغییر اندازه تصاویر، علاوه بر این که برای مدل‌های یادگیری عمیق الزامی است، در کاهش زمان پردازش و استفاده بهینه از حافظه نیز مؤثر است. در بسیاری از موارد، تصاویر با ابعاد بزرگتر ممکن است زمان آموزش مدل را به شدت افزایش دهند، بنابراین بهینه‌سازی اندازه تصاویر می‌تواند تأثیر زیادی در عملکرد نهایی مدل داشته باشد.

2-3-4- نرمال‌سازی و مقیاس‌دهی (Normalization and Scaling)

یکی دیگر از مراحل پیش‌پردازش مهم، نرمال‌سازی یا مقیاس‌دهی پیکسل‌های تصاویر است. این مرحله به این دلیل انجام می‌شود که مدل‌های یادگیری عمیق معمولاً بهتر عمل می‌کنند زمانی که داده‌ها در یک مقیاس مشخص قرار داشته

باشند. پیکسل‌های تصاویر در دیتاست FER-2013 معمولاً دارای مقادیر بین 0 تا 255 هستند. با این حال، این مقادیر باید به مقیاس نرمالتری تبدیل شوند تا مدل بتواند بهتر یاد بگیرد.

برای این کار، مقادیر پیکسل‌ها به طور معمول بر 255 تقسیم می‌شوند تا مقادیر آنها بین 0 و 1 قرار گیرد. این تغییر باعث می‌شود که الگوریتم‌های یادگیری عمیق به طور مؤثرتری وزن‌ها را به‌روز کرده و از مشکلات مربوط به گام‌های بزرگ در فرایند آموزش جلوگیری کنند. نرمال‌سازی به‌ویژه در شبکه‌های عصبی کانولوشنی (CNN) برای کاهش همبستگی‌های ناشی از داده‌های مختلف و بهبود همگرایی مدل‌ها بسیار مهم است.

3-3-4- چرخش و تغییر زاویه تصاویر (Augmentation)

برای افزایش تنوع داده‌ها و جلوگیری از overfitting (یادگیری بیش از حد مدل از داده‌های آموزشی) از تکنیک داده‌افزایی (Data Augmentation) استفاده شد. این تکنیک به طور مصنوعی تعداد تصاویر موجود در دیتاست را افزایش می‌دهد و مدل را قادر می‌سازد تا ویژگی‌های مختلف تصاویر را در شرایط گوناگون شبیه‌سازی کند. در این پروژه، برخی از تغییرات معمولی که به تصاویر اعمال شد، شامل چرخش‌های کوچک، تغییرات در زاویه دید و کشیدن تصاویر بود.

این تغییرات به مدل کمک می‌کند تا با تنوع بیشتری از تصاویر مواجه شود و در نتیجه قدرت تعمیم‌پذیری مدل افزایش یابد. به عنوان مثال، گاهی اوقات ممکن است احساسات مختلف در تصاویر چهره‌ها تحت زاویه‌های مختلف یا در نورپردازی‌های متفاوت ظاهر شوند. بنابراین، داده‌افزایی می‌تواند کمک کند تا مدل در شبیه‌سازی و شناسایی احساسات در شرایط مختلف بهتر عمل کند.

3-3-4- شفاف‌سازی (Clearance) و حذف نویز (Noise Removal)

در بسیاری از داده‌های تصویری، ممکن است تصاویری

باکیفیت پایین یا حاوی نویز وجود داشته باشد که می‌تواند بر عملکرد مدل تأثیر منفی بگذارد. در این پروژه، یکی از مراحل پیش‌پردازش، شفاف‌سازی تصاویر و حذف نویز از آنها بود. برای این کار، تکنیک‌های مختلفی مانند فیلتر گوسین (Gaussian Filter) یا فیلتر میانگین (Mean Filter) برای حذف نویز از تصاویر استفاده شد. حذف نویز از تصاویر، به‌ویژه در دیتاست‌هایی که شامل تصاویر واقعی از افراد با حالات مختلف چهره هستند، از اهمیت بالایی برخوردار است. نویز می‌تواند باعث شود که مدل‌ها ویژگی‌های اشتباهی را شبیه‌سازی کنند و در نتیجه دقت پیش‌بینی کاهش یابد. بنابراین، شفاف‌سازی تصاویر می‌تواند به طور قابل‌توجهی عملکرد مدل را بهبود دهد.

5-3-4- برچسب‌گذاری و دسته‌بندی (Labeling and Categorization)

یکی از مراحل اساسی در پیش‌پردازش داده‌ها، اطمینان از صحت برچسب‌گذاری تصاویر است. در دیتاست FER-2013، هر تصویر به یکی از 7 احساس مختلف برچسب‌گذاری شده است. این احساسات شامل شاد، غمگین، ترس، خشم، تعجب، نفرت و بی‌احساس است. اطمینان از صحت این برچسب‌ها برای آموزش درست مدل ضروری است، چرا که هر اشتباه در برچسب‌گذاری می‌تواند باعث ایجاد خطا در فرایند آموزش شود. برچسب‌گذاری صحیح باعث می‌شود که مدل بتواند احساسات را به طور دقیق شبیه‌سازی کرده و به تمیز میان دسته‌بندی‌های مختلف بپردازد. علاوه بر این، دسته‌بندی درست داده‌ها موجب تسهیل فرایند ارزیابی و مقایسه عملکرد مدل‌ها می‌شود.

مراحل پیش‌پردازش داده‌ها به‌عنوان بخش ضروری از پروژه‌های یادگیری عمیق به شمار می‌آیند و در این پروژه نیز نقش حیاتی در آماده‌سازی داده‌ها برای مدل‌های شبیه‌سازی احساسات ایفا کردند. تغییر اندازه تصاویر، نرمال‌سازی، داده‌افزایی، حذف نویز، و برچسب‌گذاری صحیح از جمله مراحل مهمی بودند که به طور قابل‌توجهی به بهبود عملکرد مدل کمک کردند. این پیش‌پردازش‌ها موجب شدند که مدل قادر باشد به دقت بیشتری احساسات مختلف را از روی چهره

انسان ها شبیه سازی و شناسایی کند.

4-4- طراحی CNN

برای طراحی یک مدل CNN ، باید لایه های مختلفی به ترتیب به مدل اضافه شوند. در اینجا یک ساختار ساده مدل CNN برای طبقه بندی تصاویر آورده شده است.

لایه پیچشی اول (Conv1)

اولین لایه پیچشی برای استخراج ویژگی های پایه از تصویر مانند لبه ها و بافت ها به کار می رود. این لایه معمولاً از چند فیلتر کوچک مثل 3×3 یا 5×5 تشکیل می شود که بر روی تصویر اعمال می شوند.

لایه پولینگ اول (MaxPooling1)

پس از لایه پیچشی، یک لایه پولینگ برای کاهش ابعاد ویژگی ها و افزایش کارایی مدل اضافه می شود. معمولاً از ماکسیمم پولینگ با سایز 2×2 استفاده می شود.

لایه پیچشی دوم (Conv2)

در این مرحله، لایه پیچشی دوم برای استخراج ویژگی های پیچیده تر از تصویر اضافه می شود. تعداد فیلترها معمولاً بیشتر از لایه اول است.

لایه پولینگ دوم (MaxPooling2)

یک لایه پولینگ دیگر برای کاهش ابعاد ویژگی ها و جلوگیری از overfitting اضافه می شود.

لایه کاملاً متصل

پس از لایه های پیچشی و پولینگ، لایه های کاملاً متصل برای طبقه بندی تصویر اضافه می شود. در این مرحله، ویژگی های استخراج شده به یک فضای یک بعدی تبدیل شده و به وسیله لایه های Dense به کلاس های مختلف اختصاص داده می شود.

4-5- آموزش مدل

آموزش مدل در این کد با استفاده از یک شبکه عصبی کانولوشنی (CNN) انجام شده است که برای شناسایی احساسات صورت بر اساس تصاویر استفاده می شود. کد شامل

مراحل مختلفی است که از پردازش داده‌ها تا تنظیم مدل و ارزیابی عملکرد آن را شامل می‌شود. در اینجا، مراحل آموزش مدل به طور گام‌به‌گام شرح داده می‌شود.

1-5-4- آماده‌سازی داده‌ها

اولین مرحله در آموزش هر مدل یادگیری ماشین، آماده‌سازی داده‌ها است. در این کد، داده‌های اولیه از یک DataFrame به نام df بارگذاری می‌شوند که شامل تصاویر صورت به صورت داده‌های پیکسلی و برچسب‌های مربوط به احساسات مختلف است. ابتدا داده‌ها به طور خاص فیلتر می‌شوند تا تنها احساسات خاصی که علاقه‌مند به شناسایی آنها هستیم، حفظ شوند. این احساسات در لیست INTERESTED_LABELS ذخیره می‌شوند که شامل مقادیر 3، 4 و 6 است. این مقادیر به برچسب‌های احساسات خاص مربوط می‌شوند، مثل غمگینی یا شادی.

پس از فیلترکردن داده‌ها، تصاویر که به صورت رشته‌ای از پیکسل‌ها ذخیره شده‌اند، تبدیل به آرایه‌های NumPy می‌شوند. این آرایه‌ها سپس به شکل 48*48 و با عمق 1 برای تصاویر خاکستری باز ساخت می‌شوند و به نوع داده float32 تبدیل می‌شوند تا برای پردازش و آموزش مدل مناسب باشند.

2-5-4- نرمال‌سازی داده‌ها

داده‌های تصاویر بعد از بازسازی باید نرمال‌سازی شوند. نرمال‌سازی به معنی مقیاس‌بندی مقادیر پیکسل‌ها به محدوده‌ای است که مدل به راحتی بتواند با آنها کار کند. در اینجا، تمام مقادیر پیکسل‌ها تقسیم بر 255 می‌شوند تا به محدوده [0, 1] تبدیل شوند. این نرمال‌سازی از آن جهت ضروری است که به مدل کمک می‌کند تا با داده‌ها سریع‌تر و بهتر آموزش ببیند، زیرا مقادیر پیکسل‌های اصلی معمولاً در محدوده [0, 255] هستند که برای شبکه‌های عصبی می‌تواند چالشبرانگیز باشد.

3-5-4- تقسیم داده‌ها به مجموعه‌های آموزش و اعتبارسنجی

قبل از آغاز فرایند آموزش، داده‌ها به دو مجموعه اصلی تقسیم می‌شوند: مجموعه آموزش و مجموعه اعتبارسنجی. این تقسیم‌بندی با استفاده از تابع `train_test_split` انجام می‌شود که داده‌ها را به صورت تصادفی و با حفظ نسبت‌های برچسب‌ها (`stratify`) به دو مجموعه تقسیم می‌کند. معمولاً درصدی از داده‌ها برای آموزش و درصدی برای اعتبارسنجی مدل در نظر گرفته می‌شود. در اینجا، 10 درصد از داده‌ها برای اعتبارسنجی اختصاص می‌یابند.

3-5-4- کدگذاری برچسب‌ها (Label Encoding):

برچسب‌های احساسات که به صورت دسته‌بندی هستند باید به صورت عددی برای مدل قابل فهم شوند. این کار با استفاده از کدگذاری برچسب‌ها (`Label Encoding`) انجام می‌شود. در این کد از `LabelEncoder` از کتابخانه `sklearn` برای این منظور استفاده شده است. این ابزار هر برچسب را به یک عدد منحصر به فرد تبدیل می‌کند. سپس این برچسب‌ها به صورت دسته‌بندی‌های یک گرمی (`One-Hot Encoding`) تبدیل می‌شوند تا برای استفاده در شبکه‌های عصبی آماده شوند.

3-5-4- ایجاد مدل شبکه عصبی کانولوشنی

در این کد، مدل اصلی از یک شبکه عصبی کانولوشنی (`CNN`) ساخته شده است که به ویژه برای پردازش تصاویر طراحی شده است. مدل از لایه‌های مختلفی تشکیل شده است که به شرح زیر است:

- لایه‌های کانولوشنی: (`Conv2D`) این لایه‌ها برای استخراج ویژگی‌های مکانی از تصاویر استفاده می‌شوند. در ابتدا از دو لایه کانولوشنی با 64 فیلتر و اندازه هسته (`kernel`) 5×5 استفاده می‌شود. سپس دو لایه کانولوشنی دیگر با 128 فیلتر و اندازه هسته 3×3 اضافه می‌شود و در نهایت دو لایه

کانولوشنی با 256 فیلتر به شبکه اضافه می‌شود. این لایه‌ها ویژگی‌های مختلف تصویر را استخراج می‌کنند، مانند لبه‌ها و بافت‌ها.

- لایه‌های ماکس پولینگ: (MaxPooling2D) این لایه‌ها برای کاهش ابعاد تصاویر استفاده می‌شوند و کمک می‌کنند تا ویژگی‌های مهم‌تر حفظ شوند و ابعاد داده کاهش یابد.
- لایه‌های dropout: این لایه‌ها برای جلوگیری از overfitting یا بیش برآزش مدل اضافه شده‌اند. در اینجا از چندین لایه dropout با درصدهای مختلف استفاده شده است.
- لایه‌های فشرده‌سازی: (Dense) در نهایت، ویژگی‌های استخراج شده از تصاویر به یک لایه فشرده (Dense) با 128 نورون و سپس به لایه خروجی با تعداد نورون‌های برابر با تعداد کلاس‌ها در اینجا سه کلاس احساسات مختلف وارد می‌شوند. لایه خروجی از تابع فعال‌سازی softmax برای تبدیل مقادیر به احتمال‌های مربوط به هر کلاس استفاده می‌کند.

4-5-6- کامپایل مدل

بعد از ساخت مدل، آن را با استفاده از تابع compile کامپایل می‌کنیم. در این مرحله، باید تابع هزینه (loss function) و الگوریتم بهینه‌سازی (optimizer) انتخاب شوند. در این کد، از categorical_crossentropy به عنوان تابع هزینه استفاده شده است؛ زیرا این مسئله یک مسئله دسته‌بندی چند کلاسه است. همچنین از الگوریتم Nadam (ترکیبی از Adam و Nesterov Accelerated Gradient) به عنوان بهینه‌ساز استفاده شده است.

4-5-7- آموزش مدل

پس از آماده‌سازی مدل، مرحله آموزش آغاز می‌شود. آموزش مدل با استفاده از تابع fit_generator انجام می‌شود که از ImageDataGenerator برای تولید داده‌ها در هنگام آموزش استفاده می‌کند. این ژنراتور داده‌ها را به طور تصادفی تغییر می‌دهد از جمله چرخش، تغییر اندازه، کشیدگی و

تغییرات دیگر تا مدل بتواند از داده‌های بیشتری استفاده کند و تعمیم بهتری داشته باشد. در اینجا از دو callback برای کنترل فرایند آموزش استفاده شده است:

- **EarlyStopping**: برای جلوگیری از overfitting، اگر مدل به مدت چند دوره بهبود نیابد، آموزش متوقف می‌شود.
- **ReduceLROnPlateau**: این callback برای کاهش نرخ یادگیری (learning rate) در صورت ثابت ماندن دقت مدل استفاده می‌شود.

8-5-4- ذخیره مدل

پس از اتمام آموزش، مدل ذخیره می‌شود تا در آینده قابل استفاده باشد. مدل به فرمت h5 ذخیره می‌شود و معماری آن نیز به فرمت yaml ذخیره می‌شود. در این کد، آموزش مدل به طور سیستماتیک و گام‌به‌گام انجام می‌شود. داده‌ها آماده‌سازی، پردازش و به مدل تغذیه می‌شوند. مدل با استفاده از تکنیک‌های مختلف شبکه عصبی کانولوشنی و بهینه‌سازی آموزش می‌یابد. در نهایت، مدل با استفاده از callbackها بهینه‌سازی می‌شود و پس از آموزش ذخیره می‌شود.

6-4- ارزیابی مدل

مدل با استفاده از چندین روش مختلف ارزیابی می‌شود که شامل ارزیابی عملکرد مدل در طی روند آموزش و ارزیابی نهایی مدل بعد از آموزش است. در ادامه، نحوه ارزیابی مدل به تفصیل توضیح داده می‌شود:

1. داده‌های ارزیابی:

مدل با استفاده از داده‌های اعتبارسنجی (Validation Set) در طول آموزش ارزیابی می‌شود. داده‌های اعتبارسنجی از داده‌های آموزشی جدا هستند و برای ارزیابی عملکرد مدل در طول فرایند آموزش استفاده می‌شوند. این داده‌ها به مدل کمک می‌کنند تا از بیش‌برازش (Overfitting) جلوگیری کند و صحت عملکرد آن را در داده‌های جدید اندازه‌گیری نماید.

مدل در هر دوره (epoch) آموزشی با استفاده از داده های اعتبارسنجی ارزیابی می شود و میزان دقت و خطای مدل محاسبه می شود.

```
history = model.fit_generator(
    train_datagen.flow(X_train, y_train, batch_size=batch_size),
    validation_data=(X_valid, y_valid),
    steps_per_epoch=len(X_train) / batch_size,
    epochs=epochs,
    callbacks=callbacks,
    use_multiprocessing=True
)
```

در اینجا، داده های اعتبارسنجی (X_valid, y_valid) به مدل داده می شوند تا پس از هر دوره آموزشی، مدل ارزیابی شود.

2. دقت و ازدست دادن (Accuracy and Loss)

در طول آموزش، دقت و ازدست دادن مدل برای هر دوره (epoch) محاسبه می شود. این مقادیر در هنگام آموزش ذخیره شده و در نهایت برای ارزیابی عملکرد مدل استفاده می شوند. دقت مدل بر اساس تعداد پیش بینی های صحیح نسبت به تعداد پیش بینی های کلی محاسبه می شود و ازدست دادن (loss) نشان دهنده اختلاف بین پیش بینی ها و برچسب های واقعی است. این دو معیار در طول آموزش نظارت شده و برای مشاهده روند بهبود یا کاهش عملکرد مدل استفاده می شوند.

3. نمودارهای دقت و ازدست دادن (Accuracy and Loss Plots)

پس از اتمام آموزش، نمودارهایی از دقت (accuracy) و ازدست دادن (loss) برای مجموعه های آموزشی و اعتبارسنجی ترسیم می شوند. این نمودارها برای مشاهده چگونگی تغییرات عملکرد مدل در طول آموزش مفید هستند.

```
sns.lineplot(history.epoch, history.history['accuracy'], label='train')
sns.lineplot(history.epoch, history.history['val_accuracy'], label='valid')
pyplot.title('Accuracy')
```

```
sns.lineplot(history.epoch, history.history['loss'], label='train')
sns.lineplot(history.epoch, history.history['val_loss'], label='valid')
pyplot.title('Loss')
```

این نمودارها به شما نشان می‌دهند که آیا مدل به درستی یاد می‌گیرد یا خیر، و آیا بیش برآزش رخ داده است یا نه.

4. ماتریس سردرگمی (Confusion Matrix) :

پس از اتمام آموزش و ارزیابی مدل با داده‌های اعتبارسنجی، برای ارزیابی دقیق‌تر عملکرد مدل، یک ماتریس سردرگمی (Confusion Matrix) ترسیم می‌شود. این ماتریس نشان می‌دهد که مدل چه تعداد پیش‌بینی درست و غلط برای هر کلاس انجام داده است

```
yhat_valid = model.predict_classes(X_valid)
scikitplot.metrics.plot_confusion_matrix(np.argmax(y_valid, axis=1), yhat_valid, figsize=(7,7))
```

این ماتریس به شما کمک می‌کند تا مشاهده کنید که کدام دسته‌ها به درستی شناسایی شده‌اند و کدام‌ها بیشتر دچار اشتباه شده‌اند. این اطلاعات برای ارزیابی کیفیت پیش‌بینی‌های مدل بسیار مهم است.

5. گزارش طبقه‌بندی (Classification Report) :

برای ارزیابی دقیق‌تر عملکرد مدل، گزارش طبقه‌بندی شامل معیارهایی مانند دقت (Precision)، یادآوری (Recall)، و نمره F1 (F1 Score) محاسبه می‌شود. این گزارش به شما کمک می‌کند تا عملکرد مدل را در هر کلاس به صورت جزئی بررسی کنید.

```
print(classification_report(y_valid, yhat_valid))
```

این گزارش جزئیات بیشتری در مورد دقت، یادآوری و F1-Score برای هر کلاس ارائه می‌دهد و به شما کمک می‌کند تا عملکرد مدل را به تفکیک هر کلاس ارزیابی کنید.

6. تصاویر تصادفی از داده‌های آزمون و پیش‌بینی‌ها:

یکی از روش‌های ارزیابی عملکرد مدل، مشاهده پیش‌بینی‌های مدل برای نمونه‌های تصادفی از داده‌های آزمون است. در کد شما، این بخش به این صورت است که برای تصاویر تصادفی از کلاس‌های مختلف مثلاً "sad" و "neutral" پیش‌بینی‌های مدل نمایش داده می‌شود:

```

fig = pyplot.figure(figsize=(18, 4))

for i, (sadidx, neuidx) in enumerate(zip(random_sad_imgs,
random_neutral_imgs)):
    # تصویر "sad"
    ax = pyplot.subplot(2, 9, i + 1)
    sample_img = X_valid[sadidx, :, :, 0]
    ax.imshow(sample_img, cmap='gray')
    ax.set_xticks([])
    ax.set_yticks([])
    pred_sad = model.predict(np.expand_dims(X_valid[sadidx], axis=0),
verbose=0)
    pred_label_sad = np.argmax(pred_sad)
    ax.set_title(f"true:sad\npred:{mapper[pred_label_sad]}")

    # تصویر "neutral"
    ax = pyplot.subplot(2, 9, i + 10)
    sample_img = X_valid[neuidx, :, :, 0]
    ax.imshow(sample_img, cmap='gray')
    ax.set_xticks([])
    ax.set_yticks([])
    pred_neu = model.predict(np.expand_dims(X_valid[neuidx], axis=0),
verbose=0)
    pred_label_neu = np.argmax(pred_neu)
    ax.set_title(f"true:neut\npred:{mapper[pred_label_neu]}")

```

در اینجا، تصاویری از دسته‌های مختلف به همراه پیش‌بینی مدل و برجسب واقعی آنها نمایش داده می‌شود. این کار به شما کمک می‌کند تا ببینید که مدل چگونه برای داده‌های جدید پیش‌بینی می‌کند و آیا نتایج آن با واقعیت همخوانی دارد یا خیر.

4-7- بهینه‌سازی مدل

در صورتی‌که مدل عملکرد مطلوبی نداشته باشد، می‌توان از تکنیک‌هایی مانند کاهش سرعت یادگیری (learning rate decay)، شبکه‌های عصبی عمیق‌تر، و یا تنظیمات داده‌افزایی بیشتر استفاده کرد. همچنین، تنظیم تعداد فیلترها و لایه‌ها نیز می‌تواند به بهبود عملکرد مدل کمک کند.

پیاده‌سازی مدل‌های CNN برای پردازش تصاویر به‌ویژه در زمینه‌های تشخیص چهره، شناسایی اشیاء، و تحلیل تصاویر

پزشکی کاربرد وسیعی دارد. این مدل‌ها به دلیل قابلیت استخراج ویژگی‌های پیچیده به طور خودکار از تصاویر، توانسته‌اند به یکی از بهترین ابزارها در یادگیری عمیق و پردازش تصویر تبدیل شوند. با استفاده از ابزارهایی مانند پایتون و کتابخانه‌هایی مانند Keras یا TensorFlow، مدل با استفاده از چندین روش بهینه‌سازی می‌شود که شامل بهینه‌سازی پارامترهای شبکه عصبی، استفاده از تکنیک‌های منظم‌سازی (regularization)، و بهینه‌سازی فرایند آموزش با استفاده از الگوریتم‌های مختلف است. در ادامه، این روش‌ها به تفصیل توضیح داده می‌شوند:

1. استفاده از بهینه‌سازهای مختلف (Optimizers):

مدل در کد بالا از دو بهینه‌ساز مختلف برای آموزش استفاده می‌کند Adam: و Nadam. این دو بهینه‌ساز به طور گسترده در مسائل یادگیری عمیق استفاده می‌شوند و هرکدام مزایای خاص خود را دارند. بهینه‌ساز Adam به دلیل استفاده از میانگین متحرک برای نرخ یادگیری و به‌روزرسانی‌های سریع، عملکرد بسیار خوبی دارد. در این کد، مدل در نهایت با استفاده از Nadam آموزش داده می‌شود، زیرا این بهینه‌ساز در این مورد به طور خاص نتایج بهتری را نشان داده است.

```
✓ optimizers = [
    optimizers.Nadam(learning_rate=0.001, beta_1=0.9, beta_2=0.999, epsilon=1e-07, name='Nadam'),
    optimizers.Adam(0.001),
]
model = build_net(optimizers[1])
```

2. استفاده از لایه‌های Dropout برای جلوگیری از بیش‌برازش: (Overfitting)

برای جلوگیری از بیش‌برازش و بهبود تعمیم‌پذیری مدل، از لایه‌ای Dropout در طول شبکه استفاده شده است. این لایه‌ها به طور تصادفی برخی از نورون‌ها را در طول آموزش غیرفعال می‌کنند تا مدل از وابستگی بیش از حد به ویژگی‌های خاص داده جلوگیری کند. استفاده از این لایه‌ها باعث می‌شود که مدل نتواند یاد

بگیرد که به ویژگی‌های خاص داده‌ها بیش از حد تکیه کند، و در نتیجه عملکرد مدل بهبود می‌یابد.

```
net.add(Dropout(0.4, name='dropout_1'))
net.add(Dropout(0.4, name='dropout_2'))
net.add(Dropout(0.5, name='dropout_3'))
net.add(Dropout(0.6, name='dropout_4'))
```

در این بخش، در هر بخش از شبکه، از Dropout با درصد‌های مختلف استفاده شده است. این کمک می‌کند تا مدل نتواند وابستگی‌های پیچیده‌ای به ویژگی‌های خاص داده‌ها پیدا کند و بتواند بهتر تعمیم یابد.

3. استفاده از Batch Normalization :

یکی دیگر از روش‌های بهینه‌سازی استفاده شده در این کد، Batch Normalization است. این تکنیک به بهینه‌سازی سرعت آموزش و کاهش مشکلات مربوط به نوسانات (instability) کمک می‌کند. با نرمال‌سازی ورودی‌ها به هر لایه، مدل می‌تواند سریع‌تر آموزش ببیند و از مشکلات مربوط به نرخ‌های یادگیری بالا جلوگیری شود.

```
net.add(BatchNormalization(name='batchnorm_1'))
net.add(BatchNormalization(name='batchnorm_2'))
net.add(BatchNormalization(name='batchnorm_3'))
net.add(BatchNormalization(name='batchnorm_4'))
net.add(BatchNormalization(name='batchnorm_5'))
net.add(BatchNormalization(name='batchnorm_6'))
net.add(BatchNormalization(name='batchnorm_7'))
```

Batch Normalization در بین لایه‌ها قرار دارد که باعث بهبود همگرایی (convergence) مدل می‌شود.

4. استفاده از Image Data Augmentation

برای مقابله با محدودیت داده‌ها و جلوگیری از بیش‌برازش، از Image Data Augmentation استفاده شده است. این تکنیک به طور تصادفی تغییراتی مانند چرخش، شیف‌ت عرضی، شیف‌ت طولی، و تغییرات مقیاس را روی تصاویر اعمال می‌کند. این

باعث می‌شود که مدل بتواند به طور مؤثرتری ویژگی‌های عمومی را یاد بگیرد و از وابستگی به داده‌های خاص جلوگیری کند.

```
train_datagen = ImageDataGenerator(
    rotation_range=15,
    width_shift_range=0.15,
    height_shift_range=0.15,
    shear_range=0.15,
    zoom_range=0.15,
    horizontal_flip=True,
)
train_datagen.fit(X_train)
```

با استفاده از این تنظیمات، مدل تصاویر بیشتری از داده‌های اصلی می‌سازد و بنابراین می‌تواند روی تنوع بیشتری از داده‌ها آموزش ببیند.

5. استفاده از Reduce Learning Rate و Early Stopping :

برای جلوگیری از بیش برآزش و همچنین بهینه‌سازی نرخ یادگیری، از دو callback مهم استفاده شده است EarlyStopping و ReduceLROnPlateau.

- EarlyStopping به این صورت کار می‌کند که در صورت عدم بهبود مدل در معیارهای خاص در اینجا دقت اعتبارسنجی، آموزش متوقف می‌شود. این روش باعث می‌شود که آموزش در زمانی که مدل دیگر قادر به یادگیری بهتر نیست، متوقف شود.

```
early_stopping = EarlyStopping(
    monitor='val_accuracy',
    min_delta=0.00005,
    patience=11,
    verbose=1,
    restore_best_weights=True,
)
```

ReduceLROnPlateau به طور خودکار نرخ یادگیری را کاهش می‌دهد زمانی که مدل نمی‌تواند بهبود بیشتری در معیار موردنظر در اینجا دقت اعتبارسنجی ایجاد کند. این به مدل کمک می‌کند که با نرخ یادگیری کمتر، به بهینه‌سازی دقیق‌تر بپردازد.

```
lr_scheduler = ReduceLROnPlateau(
    monitor='val_accuracy',
    factor=0.5,
    patience=7,
    min_lr=1e-7,
    verbose=1,
)
```

این دو تکنیک باعث می‌شوند که مدل در صورت عدم بهبود در داده‌های اعتبارسنجی، آموزش را متوقف کند یا نرخ یادگیری را کاهش دهد، به‌طوری‌که یادگیری ادامه یابد ولی از بیش برآزش جلوگیری شود.

6. استفاده از He Normal Initialization:

در لایه‌های مختلف شبکه، از He Normal Initialization برای مقداردهی اولیه وزن‌ها استفاده شده است. این تکنیک باعث می‌شود که وزن‌ها به‌گونه‌ای مقداردهی شوند که همگرایی مدل سریع‌تر و پایدارتر باشد، به‌ویژه در لایه‌هایی که از توابع فعال‌سازی مانند ELU استفاده می‌شود.

```
kernel_initializer='he_normal'
```


7. استفاده از Convolutional Layers برای استخراج ویژگی‌ها: شبکه عصبی کانولوشنی (CNN) به طور خاص برای پردازش داده‌های تصویری طراحی شده است. استفاده از لایه‌های Conv2D در کد به مدل کمک می‌کند تا ویژگی‌های مهم از تصاویر ورودی را استخراج کند. لایه‌های مختلف Conv2D با فیلترهای مختلف به طور مرحله‌ای ویژگی‌های پیچیده‌تری از تصاویر را شناسایی می‌کنند، و این باعث بهبود قدرت مدل در شناسایی الگوها و ویژگی‌ها می‌شود. در مجموع، مدل در این کد با استفاده از چندین تکنیک بهینه‌سازی مهم مانند استفاده از بهینه‌سازهای مختلف

Adam و Dropout، Nadam برای جلوگیری از بیش برآزش، Batch Normalization برای بهبود همگرایی، Image Data Augmentation برای افزایش تنوع داده‌ها، Early Stopping و ReduceLROnPlateau برای بهینه‌سازی فرایند آموزش و نرخ یادگیری، و He Normal Initialization برای بهینه‌سازی مقداردهی اولیه وزن‌ها بهینه‌سازی شده است. این روش‌ها کمک می‌کنند که مدل به طور مؤثرتری یاد بگیرد و به نتایج بهتری دست یابد.


4-8- نتیجه‌گیری

در این فصل پیاده سازی یک شبکه عصبی مصنوعی عمیق با کمک شبکه های کانولوشنی و سپس آموزش و ارزیابی و در نهایت بهینه سازی آن مورد بحث قرار گرفت. در فصل بعد جمع بندی نهایی از کارهای انجام شده در این پژوهش ارائه می‌شود.

4-9- تحلیل عملکرد مدل یادگیری عمیق



شکل 4-9-1



شکل 2-9-4

نمودارهای آموزش (Training History)

نمودارهای مربوط به دقت (Accuracy) و خطا (Loss) در طول مراحل آموزش مدل به شرح زیر هستند:

1. نمودار Accuracy:

- محور افقی: تعداد epoch ها (تا 50)
- محور عمودی: دقت مدل (Accuracy)
- منحنی آبی: داده‌های آموزش (Train)
- منحنی قرمز: داده‌های اعتبار‌سنجی (Validation)

مشاهدات:

- دقت از حدود 0.45 شروع شده و تا حدود 0.85 برای هر دو مجموعه افزایش پیدا

کرده است.

- نوسانات در داده‌های Validation دیده می‌شود، اما در نهایت به دقت مشابه با آموزش می‌رسد.
- مدل دچار overfitting نشده است.

2 نمودار Loss

- هر دو مجموعه آموزش و اعتبارسنجی کاهش loss خوبی داشته‌اند.
- مقدار loss مجموعه اعتبارسنجی کمی بالاتر از آموزش است، اما تفاوت قابل توجهی ندارد.
- تایید می‌کند که مدل به خوبی یاد گرفته و overfitting یا underfitting ندارد.

گزارش عملکرد مدل

بر اساس گزارش Precision، Recall و FI-score برای سه کلاس مختلف، نتایج زیر به دست آمده است:

تعداد نمونه	FI-score	Recall	Precision	کلاس
899	0.92	0.91	0.93	0
608	0.77	0.76	0.77	1
620	0.75	0.76	0.73	2

میانگین‌ها:

-دقت کلی (Accuracy): 0.82 یا 82%

-میانگین وزنی FI-score: 0.82

تحلیل Confusion Matrix

ماتریس سردرگمی عملکرد مدل در تشخیص سه کلاس را نشان می‌دهد. محور عمودی برچسب واقعی و محور افقی پیش‌بینی مدل است.

	Pred 0	Pred 1	Pred 2
True 0	820	24	55
True 1	28	461	119
True 2	38	110	472

تحلیل:

- بیشترین دقت برای کلاس 0 است (احتمالاً احساس مثبت).
- بیشترین خطاها بین کلاس‌های 1 و 2 رخ داده که نشان‌دهنده شباهت آن‌هاست.

جمع‌بندی نهایی

- دقت نهایی مدل: حدود 82-83%
- عملکرد قوی در کلاس 0
- افت دقت در کلاس‌های 1 و 2 به دلیل شباهت ویژگی‌ها
- عدم وجود **overfitting** در مدل
- پیشنهادهای برای بهبود:
 - افزایش داده‌های کلاس‌های 1 و 2
 - استفاده از تکنیک‌های **data augmentation** یا **class weighting**
 - استفاده از مدل‌های پیشرفته‌تر یا مدل‌های **pre-trained**

فصل 5:

جمع‌بندی و پیشنهادها

1-5- نتیجه‌گیری

در ارزیابی عملکرد مدل، ابتدا باید به این نکته اشاره کرد که مدل در داده‌های آموزشی و اعتبارسنجی عملکرد قابل‌قبولی داشته است. این نشان‌دهنده توانایی مدل در یادگیری الگوهای صحیح از داده‌ها و انتقال این اطلاعات به داده‌های جدید است. دقت مدل به‌طورکلی در هر دو مجموعه آموزشی و اعتبارسنجی نشان‌دهنده این است که مدل قادر است به‌خوبی احساسات مختلف را شناسایی کند و این امر از لحاظ علمی و تجربی تأیید می‌شود.

توزیع عملکرد مدل که به طور خاص شامل تحلیل ویژگی‌های داده‌ها است، به طور مستقیم نشان می‌دهد که مدل در استفاده از ویژگی‌ها به طور یکنواخت عمل کرده است. در واقع، این توزیع عملکرد نشان می‌دهد که مدل نمی‌تواند تنها به چند ویژگی خاص اتکا کند، بلکه به طور یکسان از تمامی ویژگی‌های موجود در داده‌ها برای شناسایی احساسات استفاده می‌کند. این ویژگی از آن‌جهت اهمیت دارد که مانع از بروز bias یا جانبداری در پیش‌بینی‌ها می‌شود و به مدل این امکان را می‌دهد که به طور دقیق‌تر و منصفانه‌تر عمل کند.

علاوه بر توزیع عملکرد، ماتریس سردرگمی (confusion matrix) گزارش طبقه‌بندی (classification report) اطلاعات مفیدی در خصوص عملکرد مدل روی هر دسته‌بندی احساسات مختلف ارائه می‌دهند. این ابزارها به طور خاص نشان می‌دهند که مدل در شناسایی هر احساس به طور دقیق چه میزان موفق بوده است. برای مثال، مدل ممکن است در شناسایی احساس "خشم" عملکرد بهتری نسبت به شناسایی احساس "غم" داشته باشد، و این تفاوت‌ها از طریق تجزیه و تحلیل confusion matrix مشخص می‌شود. این اطلاعات به ما کمک می‌کند که نقاط ضعف مدل را شناسایی کرده و در صورت نیاز، اصلاحات لازم را انجام دهیم.

یکی از دیگر ابزارهایی که در تحلیل عملکرد مدل مفید واقع می‌شود، نمودارهای دقت و Loss است. این نمودارها که در طول فرایند آموزش مدل به طور پیوسته به‌روزرسانی می‌شوند، اطلاعات مهمی را در خصوص چگونگی یادگیری مدل

در اختیار می‌گذارند. نمودار دقت نشان‌دهنده این است که مدل به طور پیوسته در حال بهبود دقت پیش‌بینی‌های خود است، و از آنجایی که هیچ‌گونه overfitting از در این نمودار مشاهده نمی‌شود، می‌توان نتیجه گرفت که مدل به‌خوبی قادر به تعمیم داده‌های آموزشی به داده‌های جدید است. نمودار loss نیز درک بهتری از روند یادگیری مدل به ما می‌دهد. این نمودار نشان می‌دهد که مدل در حال کاهش خطای خود است و فرایند آموزش به‌درستی پیش می‌رود. اگر loss در طول زمان کاهش یابد، این به معنای بهبود عملکرد مدل است. باتوجه به این نمودارها، می‌توانیم به طور دقیق متوجه شویم که آیا مدل به طور بهینه آموزش‌دیده است یا خیر.

پیش‌بینی‌های تصادفی از نمونه‌ها نیز به طور بصری نشان‌دهنده توانایی مدل در شناسایی دقیق احساسات مختلف هستند. برای مثال، مدل ممکن است در شناسایی احساسات خاصی مانند غم یا خوشحالی عملکرد بهتری داشته باشد. این پیش‌بینی‌ها به طور معمول با مقایسه خروجی مدل و برچسب‌های واقعی داده‌ها ارزیابی می‌شوند. اگر مدل پیش‌بینی‌های دقیقی برای دسته‌های خاصی مانند "غم" یا "خوشحالی" ارائه دهد، این نشان‌دهنده این است که مدل در یادگیری ویژگی‌های خاص این احساسات موفق بوده است. در نهایت، باتوجه به تحلیل‌های صورت‌گرفته از جمله توزیع عملکرد، confusion matrix، classification report، نمودارهای دقت و loss، و پیش‌بینی‌های تصادفی، می‌توان نتیجه گرفت که مدل به‌طور کلی عملکرد خوبی از خود نشان داده است. این مدل توانسته است احساسات مختلف را به‌خوبی شناسایی کند و در دسته‌بندی آنها دقت بالایی داشته باشد. با این حال، باتوجه به این که همیشه جای بهبود وجود دارد، مدل ممکن است نیاز به بهینه‌سازی‌های بیشتری داشته باشد. بهینه‌سازی‌هایی مانند تنظیمات هایپرپارامترها یا افزایش داده‌ها می‌تواند به بهبود دقت مدل کمک کند. این اقدامات می‌توانند باعث بهینه‌تر شدن عملکرد مدل و افزایش قابلیت تعمیم آن به داده‌های جدید شوند. در نهایت، می‌توان گفت که باتوجه به ارزیابی‌های صورت‌گرفته، مدل از نظر کلی عملکرد قابل‌قبولی داشته و قادر است احساسات مختلف را شناسایی کند. اما برای

رسیدن به دقت بالاتر و کارایی بیشتر، لازم است که همچنان به فرایند بهینه‌سازی ادامه داده و روش‌هایی مانند افزایش داده‌ها یا تغییر پارامترهای مدل را موردبررسی قرار داد. برای تکمیل ارزیابی مدل و درک بهتر از نقاط قوت و ضعف آن، باید به جنبه‌های دیگری از عملکرد مدل نیز پرداخته شود که می‌تواند در بهینه‌سازی و بهبود نتایج نهایی مؤثر باشد.

یکی از این جنبه‌ها بررسی تأثیر پیش‌پردازش داده‌ها و انتخاب ویژگی‌ها بر عملکرد مدل است. انتخاب صحیح ویژگی‌ها به مدل این امکان را می‌دهد که اطلاعات مفیدی از داده‌ها استخراج کند و در نتیجه شناسایی احساسات بادقت بالاتری صورت گیرد. در صورتی‌که ویژگی‌های نامناسب یا اضافی وارد مدل شوند، ممکن است دقت آن کاهش یابد. به همین دلیل، انجام یک فرایند مناسب برای انتخاب ویژگی‌ها می‌تواند نقش زیادی در بهبود نتایج داشته باشد. همچنین، ارزیابی دقیق مدل باید شامل بررسی عملکرد آن در شرایط مختلف باشد. به عنوان مثال، آیا مدل قادر به شناسایی احساسات در شرایط مختلف نور، زاویه یا کیفیت تصویر است؟ بسیاری از مدل‌های شناسایی احساسات ممکن است در شرایط خاص یا بر روی داده‌های کم‌کیفیت عملکرد ضعیفی داشته باشند. بنابراین، بررسی رفتار مدل در شرایط مختلف می‌تواند به شناسایی نقاط ضعف آن کمک کند و در نهایت به بهینه‌سازی‌های لازم منتهی شود.

علاوه بر این، تحلیل دقیق عملکرد مدل روی دسته‌بندی‌های خاص احساسات نیز از اهمیت بالایی برخوردار است. برخی از احساسات ممکن است برای مدل چالش‌برانگیزتر باشند، به‌ویژه اگر تعداد نمونه‌های موجود برای آن احساس کمتر باشد. این مشکل می‌تواند منجر به کاهش دقت مدل در شناسایی آن احساسات خاص شود. در این شرایط، استفاده از تکنیک‌هایی مانند augmenting داده‌ها یا استفاده از مدل‌های پیشرفته‌تر می‌تواند به مدل کمک کند تا عملکرد بهتری در شناسایی این دسته‌ها داشته باشد.

همچنین، بررسی بیشتر در خصوص تکنیک‌های بهبود عملکرد، مانند استفاده از الگوریتم‌های یادگیری عمیق پیشرفته‌تر و معماری‌های مدل پیچیده‌تر، می‌تواند نتایج بهتری را به همراه داشته باشد. برای مثال، مدل‌های CNN شبکه‌های عصبی

کانولوشنی یا LSTM مدل‌های حافظه کوتاه‌مدت بلند برای تحلیل داده‌های تصویری و زمانی به طور خاص طراحی شده‌اند، می‌توانند دقت مدل را در شناسایی احساسات افزایش دهند. این مدل‌ها با بهره‌گیری از ویژگی‌های مختلف داده‌های تصویری و زمانی، قادر به شناسایی دقیق‌تری از ویژگی‌های صورت و همچنین رفتارهای احساسی مرتبط با آنها هستند.

از سوی دیگر، بررسی دقیق تنظیمات هایپرپارامترها نیز می‌تواند تأثیر زیادی در عملکرد مدل داشته باشد. هایپرپارامترهایی مانند نرخ یادگیری، تعداد لایه‌ها و اندازه دسته‌بندی می‌توانند بر سرعت و دقت مدل تأثیرگذار باشند. انتخاب صحیح این پارامترها می‌تواند باعث افزایش توانایی مدل در تعمیم به داده‌های جدید شود و از overfitting جلوگیری کند.

به‌طور کلی، ارزیابی دقیق و جامع از عملکرد مدل که شامل تجزیه و تحلیل جزئیات مختلفی از قبیل انتخاب ویژگی‌ها، تکنیک‌های پیش‌پردازش، رفتار مدل در شرایط مختلف، و تنظیمات هایپرپارامترها است، به شناسایی نقاط ضعف و قدرت مدل کمک می‌کند. علاوه بر این، استفاده از تکنیک‌های پیشرفته‌تر و اصلاحات به‌موقع می‌تواند به مدل این امکان را بدهد که نتایج دقیق‌تر و کارآمدتری ارائه دهد. این اقدامات در نهایت به بهبود شناسایی احساسات کمک می‌کنند و مدل را قادر می‌سازند تا به یک ابزار قدرتمند و مؤثر در کاربردهای مختلف مانند شناسایی احساسات در تعاملات انسانی یا تحلیل داده‌های رسانه‌های اجتماعی تبدیل شود.

2-5- مشکلات و محدودیت‌ها

1-2-5- مشکلات مربوط به داده‌ها

الف. داده‌های نامتعادل: وقتی تعداد زیادی نمونه از برخی احساسات نسبت به دیگر احساسات وجود داشت مثل خوشحالی بیشتر از غم یا ترس، مدل به سمت دسته‌های غالب میل کرد و قادر به شناسایی دقیق دسته‌های کمتر مشاهده‌شده نبود. این مشکل باعث کاهش دقت مدل در

پیش‌بینی احساسات نادرتر شد.

ب. کیفیت پایین داده‌ها: برخی از تصاویر ورودی کیفیت پایین یا نویز داشتند که موجب کاهش دقت مدل شد. به‌ویژه اگر تصاویر نادرست برچسب‌گذاری شده بودند، مدل نتایج غلطی تولید کرد.

ج. پیش‌پردازش داده‌ها: مراحل پیش‌پردازش نادرست مانند نرمالیزه‌نکردن داده‌ها، اشتباه در تبدیل داده‌ها یا اندازه‌گیری نامناسب باعث آسیب به مدل و کاهش عملکرد آن شد.

2-2-5- مشکلات مربوط به معماری و تنظیمات مدل

الف. طراحی پیچیده مدل Deep Convolutional Neural Network (DCNN) که استفاده کردم، دارای لایه‌های زیادی بود که نیاز به تنظیم دقیقه‌ای پارامترها مانند تعداد فیلترها، اندازه فیلترها و عمق شبکه داشت. این پیچیدگی‌ها باعث شد که مدل دچار overfitting یا underfitting شود.

ب. تنظیم نادرست هایپرپارامترها: انتخاب نادرست پارامترهایی مثل نرخ یادگیری، تعداد epochs، یا استفاده از مقادیر نامناسب برای پارامترهای شبکه باعث کاهش عملکرد مدل شد. برای مثال، نرخ یادگیری بسیار بالا مدل را از هم‌گسیخته کرد و باعث یادگیری نادرست شد.

ج. یکی از چالش‌های اصلی که در روند پیاده‌سازی با آن مواجه شدم، تنظیم دقیق هایپرپارامترها بود. انتخاب بهترین نرخ یادگیری، تعداد epochs، و اندازه batch اهمیت زیادی داشتند. برای تنظیم‌های دقیق، از تکنیک‌هایی مانند Grid Search و Random Search استفاده کردم تا مجموعه‌ای از پارامترهای مختلف را آزمایش کنم و بهترین ترکیب را پیدا کنم. علاوه بر این، استفاده از تکنیک‌هایی مانند Learning Rate Scheduling می‌تواند به بهبود روند آموزش کمک کند و از افت شدید نرخ یادگیری جلوگیری کند.

د. Overfitting مدل‌های پیچیده مانند DCNN به راحتی با داده‌های آموزشی سازگار شدند و در نتیجه نتوانستند به خوبی روی داده‌های جدید یا داده‌های تست عمل کنند.

برای مقابله با این مشکل، از تکنیک‌های مانند dropout و early stopping استفاده کردم، اما هنوز نیاز به تنظیمات دقیق‌تری بود.

برخی از لایه‌های موجود در معماری اولیه مدل DCNN به نظر می‌رسید که نیاز به بهینه‌سازی دارند. از این‌رو، با استفاده از لایه‌های مختلفی مانند Batch Normalization و Activations مختلف مانند ReLU به جای Sigmoid، سعی کردم که بهبودهای قابل‌توجهی در عملکرد مدل ایجاد کنم. این تغییرات باعث کاهش Overfitting و بهبود یادگیری مدل شد. ه. استفاده از Regularization برای جلوگیری از Overfitting در مدل، از تکنیک‌های regularization مانند L2 regularization و Dropout استفاده کردم. L2 regularization به کاهش وزن‌های مدل کمک می‌کند و از بزرگ‌شدن غیرضروری وزن‌ها جلوگیری می‌کند، درحالی‌که Dropout به مدل کمک می‌کند تا به جای وابستگی بیش از حد به ویژگی‌های خاص، به ویژگی‌های عمومی‌تر توجه کند.

3-2-5- محدودیت‌های منابع محاسباتی

الف. زمان آموزش طولانی: مدل‌های پیچیده Deep CNN زمان زیادی برای آموزش نیاز دارند. وقتی داده‌های زیادی وجود داشتند، زمان آموزش بسیار طولانی شد. در صورت محدودیت منابع سخت‌افزاری مثلاً عدم دسترسی به GPU، این مشکل تشدید شد.

ب. محدودیت‌های حافظه: مدل‌های پیچیده که شامل لایه‌های زیادی بودند، حافظه زیادی مصرف کردند. این مسئله به‌ویژه زمانی که از تصاویر با وضوح بالا استفاده می‌کردم، به مشکل برخورد. مدل در زمان آموزش با خطاهای حافظه روبرو شد یا مجبور شدم اندازه batch‌ها را کاهش دهم که این خود باعث کاهش عملکرد مدل شد.

4-2-5- چالش‌ها در ارزیابی مدل

الف. ارزیابی نادرست بادقت (Accuracy): اگر داده‌ها نامتعادل بودند، تنها استفاده از معیار دقت (Accuracy)

نتایج گمراه‌کننده‌ای به همراه داشت. برای مثال، اگر دسته‌ای از احساسات بسیار غالب بود، مدل می‌توانست به‌سادگی پیش‌بینی‌های درست انجام دهد، اما عملکرد آن در دسته‌های کمتر مشاهده شده بسیار ضعیف بود. در این مواقع از معیارهای دیگری مانند حساسیت (Recall)، دقت (Precision) و F1-score استفاده کردم. o چالش‌های تحلیل ب. نتایج confusion matrix: از آنجاکه داده‌ها ممکن بود نامتعادل باشند، مدل دچار مشکلاتی در شناسایی برخی از کلاس‌ها شد. در این صورت، تحلیل confusion matrix به من کمک کرد تا دقیق‌تر بفهمم کجا مدل دچار مشکل می‌شود. اگر برخی از احساسات به‌درستی شناسایی نمی‌شدند، علت آن را تجزیه و تحلیل کردم.

5-3- پیشنهادهایی برای کارهای آتی

برای بهبود الگوریتم‌ها و روش‌ها در تحقیقات آینده مرتبط با کد فرستاده شده، می‌توان چندین توصیه کلیدی داشت که می‌تواند به ارتقا دقت مدل، سرعت آموزش، و عملکرد کلی مدل کمک کند. این توصیه‌ها شامل بهبود داده‌ها، بهینه‌سازی مدل، استفاده از تکنیک‌های پیشرفته، و ارزیابی دقیق‌تر است.

5-3-1- بهبود کیفیت داده‌ها

- افزایش تنوع داده‌ها: برای بهبود عملکرد مدل در شناسایی احساسات مختلف، لازم است که داده‌ها از تنوع فرهنگی و شرایط مختلف نور، پس‌زمینه، کیفیت تصویر برخوردار باشند. به این منظور، می‌توان از داده‌های جدید یا از داده‌های جمع‌آوری شده از منابع مختلف استفاده کرد.

- افزایش حجم داده‌ها: یکی از روش‌های مؤثر برای بهبود عملکرد مدل در مسائل یادگیری عمیق، افزایش حجم داده‌ها است. اگر داده‌ها محدود باشند، استفاده از تکنیک‌هایی مانند Data Augmentation و Transfer Learning می‌تواند مفید باشد.

همچنین، اضافه کردن داده‌های مصنوعی با استفاده از تکنیک‌های Generative Adversarial Networks (GANs) نیز می‌تواند کمک‌کننده باشد.

• برچسب‌گذاری دقیق‌تر داده‌ها: برچسب‌های نادرست یا اشتباه می‌تواند موجب کاهش دقت مدل شود. انجام فرایند برچسب‌گذاری دقیق‌تر و بازنگری داده‌ها برای تصحیح اشتباهات برچسب‌گذاری می‌تواند به طور چشمگیری مدل را بهبود دهد.

2-3-5- بهینه‌سازی معماری مدل

• استفاده از مدل‌های پیش آموزش‌داده شده: (Transfer Learning) در بسیاری از مسائل شناسایی تصاویر، استفاده از مدل‌های پیش آموزش‌داده شده مثل VGG16, ResNet, InceptionNet می‌تواند باعث افزایش دقت و کاهش زمان آموزش شود. این مدل‌ها می‌توانند ویژگی‌های پیچیده‌ای را که برای تشخیص احساسات لازم است، استخراج کنند و نیاز به آموزش مدل از صفر را کاهش دهند.

• استفاده از معماری‌های پیچیده‌تر: مدل‌های موجود (DCNN) ممکن است با توجه به پیچیدگی مسئله به دقت مطلوب نرسند. می‌توان از مدل‌های پیشرفته‌تری مانند DenseNet, EfficientNet، یا Xception استفاده کرد که قادرند ویژگی‌های بسیار پیچیده‌تری را استخراج کرده و عملکرد مدل را بهبود دهند.

• بهبود لایه‌های مدل: استفاده از Residual Connections اتصال‌های باقیمانده که در مدل‌هایی مانند ResNet موجود است، می‌تواند به کاهش مشکلاتی مانند Vanishing Gradient کمک کرده و آموزش مدل را کارآمدتر کند.

3-3-5- استفاده از تکنیک‌های بهینه‌سازی پیشرفته

• بهینه‌سازی خودکار هاپرپارامترها: تنظیم دستی هاپرپارامترها زمان‌بر و چالش‌برانگیز است. استفاده از

تکنیک‌هایی مانند Bayesian Optimization، Grid Search، یا Random Search برای پیدا کردن بهترین ترکیب هایپرپارامترها می‌تواند کمک زیادی به بهینه‌سازی مدل بکند.

- استفاده از الگوریتم‌های بهینه‌سازی پیشرفته: علاوه بر Adam و Nadam، استفاده از الگوریتم‌های بهینه‌سازی جدید مانند Ranger، LookAhead، یا LAMB Layer-wise Adaptive Moments optimizer می‌تواند سرعت همگرایی را افزایش داده و دقت مدل را ارتقا دهد.

4-3-5- استفاده از تکنیک‌های مقابله با overfitting

- استفاده از Dropout بیشتر: اگر مدل هنوز دچار overfitting شود، می‌توان درصد dropout را افزایش داد یا تکنیک‌های دیگری مثل Early Stopping یا L2 Regularization را استفاده کرد.
- استفاده از Batch Normalization در لایه‌های بیشتری: این تکنیک می‌تواند باعث تسریع روند آموزش و کاهش اثرات overfitting شود. اضافه کردن Batch Normalization به لایه‌های بیشتر مدل می‌تواند مفید باشد.
- استفاده از Ensemble Learning: ترکیب چند مدل مختلف مثل مدل‌های با معماری‌های مختلف می‌تواند دقت مدل را افزایش دهد و از overfitting جلوگیری کند.

4-3-5- بهبود ارزیابی مدل

- استفاده از معیارهای ارزیابی متعدد: تنها استفاده از دقت (accuracy) برای ارزیابی مدل مناسب نیست، به‌خصوص در صورت وجود داده‌های نامتعادل. معیارهایی مانند ROC Curve، Precision، Recall، F1-Score، Confusion Matrix، و AUC باید برای ارزیابی عملکرد مدل استفاده شوند.
- استفاده از K-fold Cross-Validation: به جای استفاده از یک مجموعه آموزش و اعتبارسنجی ثابت، می‌توان از K-fold Cross-Validation برای ارزیابی مدل استفاده کرد تا اطمینان حاصل شود که مدل روی تمامی داده‌ها به طور مؤثر آموزش‌دیده و

ارزیابی شده است.

- ارزیابی مدل روی داده‌های واقعی: برای ارزیابی نهایی مدل، می‌توان از داده‌های جدید یا داده‌هایی که در طی آموزش استفاده نشده‌اند، استفاده کرد. این کار باعث می‌شود تا از overfitting جلوگیری شود و عملکرد مدل در دنیای واقعی ارزیابی شود.

6-3-5- پیشرفت در پیش‌پردازش داده‌ها

- استفاده از پیش‌پردازش تصاویر پیشرفته: پیش‌پردازش داده‌ها می‌تواند تأثیر زیادی بر روی دقت مدل داشته باشد. استفاده از تکنیک‌های پیشرفته‌تر مانند Histogram Equalization برای بهبود کنتراست تصاویر و یا CLAHE Contrast Limited Adaptive Histogram Equalization می‌تواند به شناسایی بهتر ویژگی‌ها در تصاویر کمک کند.
- تقویت تصاویر برای داده‌های کمتر دیده‌شده: در صورتی که احساساتی مانند "ترس" یا "تعجب" کمتر در داده‌ها موجود باشد، باید از تکنیک‌های Data Augmentation مانند چرخش، برش، تغییر اندازه، و تغییرات رنگی استفاده کرد.

منابع

فهرست منابع

نمونه مقاله

- [1] V. R. Voller, "A Fixed Grid Numerical Modeling Methodology For Convection-Diffusion Mushy Region Phase-Change Problems", *Int. J. Heat and Mass Transfer*, Vol. 30, No. 8, pp-1709-1719, (1987)
- [2] دژکام، مهدی، "تشخیص احساسات بر اساس تصویر چهره با استفاده از یادگیری عمیق"، پایان‌نامه کارشناسی ارشد، دانشگاه آزاد اسلامی سبزوار، ۱۳۹۶
- [3] شریف نژاد، مائده و شاه بهرامی، اسدالله و آکوشیده، علیرضا، ۱۳۹۹، روش‌های شناسایی احساسات چهره، کاربردها و چالش‌ها <https://civilica.com/doc/1901513/>
- [4] صادقی، مریم و غیب الهی، الهه و میرزایی، مهنام، ۱۴۰۳، تشخیص احساسات از روی چهره به روش BIMODAL و طبقه‌بندی svm و فیلتر گابور با نرم افزار متلب، هجدهمین کنفرانس بین‌المللی نوآوری و تحقیق در علوم مهندسی <https://civilica.com/doc/2064574/>
- [5] عرب گنگان، حدیثه و حسینی، سید علی و روحانی، مهرداد، ۱۴۰۳، شناسایی احساسات از روی تصویر چهره با استفاده از یادگیری انتقالی و اصلاح بر روی معماری ۱۶VGG، هفتمین همایش ملی فناوریهای نوین در مهندسی برق، کامپیوتر و مکانیک ایران، تهران <https://civilica.com/doc/2050341/>
- [6] غفرانی، علی و قنبری، شیرین و مهدیان، راهیل، ۱۳۹۷، تشخیص چهره و شناسایی بی‌درنگ حالت عاطفی صورت بر مبنای یادگیری عمیق، پانزدهمین اجلاس سراسری فناوری رسانه، تهران
- [7] ولی منفرد، محبوبه و شمسی، محبوبه و محجل، مرتضی، ۱۴۰۰، تشخیص حالت چهره با یادگیری عمیق، پنجمین کنفرانس ملی کامپیوتر، فناوری اطلاعات و کاربردهای هوش مصنوعی، اهواز
- [8] Jaiswal, A. Krishnama Raju and S. Deb, "Facial Emotion Detection Using Deep Learning," 2020 *International Conference for Emerging Technology (INCET)*, Belgaum, India, 2020, pp. 1-5
- [9] Ballesteros, Jesús A, et al. "Facial Emotion Recognition through Artificial Intelligence." *Frontiers in Computer Science*, vol. 6, 31 Jan. 2024, <https://doi.org/10.3389/fcomp.2024.1359471>.
- [10] Dores, Artemisa R et al. "Recognizing Emotions through Facial Expressions: A Largescale Experimental Study." *International journal of environmental research and public health* vol. 17,20 7420. 12 Oct. 2020
- I. Agrawal, A. Kumar, D. Swathi, V. Yashwanthi and R. Hegde, "Emotion Recognition from Facial Expression using CNN," 2021 *IEEE 9th Region 10 Humanitarian Technology Conference (R10-HTC)*, Bangalore, India, 2021, pp. 01-06,
- [11] Khairuddin, Yousif, and Zhuofa Chen. "Facial Emotion Recognition: State of the Art Performance on FER2013." *ArXiv:2105.03588 [Cs]*, 8 May 2021
- [12] Khan, Amjad Rehman. 2022. "Facial Emotion Recognition Using Conventional Machine Learning and Deep Learning Methods: Current Achievements, Analysis and Remaining Challenges" *Information* 13, no. 6: 268.

[13] Mehendale, N. Facial emotion recognition using convolutional neural networks (FERC). SN Appl. Sci. 2, 446 (2020)

1-عنوان: تشخیص احساسات از روی چهره به روش BIMODAL و طبقه‌بندی SVM و فیلتر گابور با نرم‌افزار متلب
نویسندگان: مریم صادقی، الهه غیب‌اللهی، مهنام میرزایی
سال: ۱۴۰۳
لینک: <https://civilica.com/doc/2064574/>
تاریخی که بررسی شد: ۲ اسفند ۱۴۰۳

2-عنوان: شناسایی احساسات از روی تصویر چهره با استفاده از یادگیری انتقالی و اصلاح بر روی معماری VGG-16
نویسندگان: حدیثه عرب گنگان، سیدعلی حسینی، مهرداد روحانی
سال: ۱۴۰۳
لینک: <https://civilica.com/doc/2050341/>
تاریخی که بررسی شد: ۲ اسفند ۱۴۰۳

3-عنوان: روش‌های شناسایی احساسات چهره، کاربردها و چالش‌ها
نویسندگان: مانده شریف‌نژاد، اسدالله شاه‌بهرامی، علیرضا آکوشیده
سال: ۱۳۹۹
لینک: <https://civilica.com/doc/1901513/>
تاریخی که بررسی شد: ۳ اسفند ۱۴۰۳

4-عنوان: Face recognition methods and algorithms
نویسنده: مشخص نیست
سال: مشخص نیست
لینک: <https://matlabkar.com/face-recognition-methods-andalgorithms/>
تاریخی که بررسی شد: ۳ اسفند ۱۴۰۳

5-عنوان: تشخیص حالت چهره با یادگیری عمیق
نویسندگان: محبوبه ولی‌منفرد، محبوبه شمسی، مرتضی محجل
سال: ۱۴۰۰
لینک: <https://civilica.com/doc/1428814/>
تاریخی که بررسی شد: ۴ اسفند ۱۴۰۳

6-عنوان: مشخص نیست، احتمالاً پردازش تصویر و یادگیری ماشین در تشخیص چهره
نویسنده: نامشخص
سال: بین ۱۳۹۵ تا ۱۴۰۰

لینک: <https://civilica.com/doc/1040343/>
تاریخی که بررسی شد: ۴ اسفند ۱۴۰۳

7-عنوان: روش‌های نوین شناسایی چهره و کاربردها)
نویسنده: نامشخص
سال: حدود ۱۳۹۵
لینک: <https://civilica.com/doc/822375/>
تاریخی که بررسی شد: ۵ اسفند ۱۴۰۳

8-عنوان: پایان‌نامه در زمینه شناسایی احساسات چهره)
نویسنده: دانشجوی دانشگاه آزاد اسلامی
سال: حدود ۱۳۹۸
لینک: <https://theses.iaus.ac.ir/Abstract/thesis-7727.html>
تاریخی که بررسی شد: ۵ اسفند ۱۴۰۳

9-عنوان: مقاله علمی جدید در حوزه یادگیری ماشین و شناسایی احساسات چهره)
نویسندگان: محققان بین‌المللی
سال: ۲۰۲۴
لینک: <https://www.frontiersin.org/journals/computerscience/articles/10.3389/fcomp.2024.1359471/full>
تاریخی که بررسی شد: ۶ اسفند ۱۴۰۳

10-عنوان: کاربرد یادگیری عمیق در پردازش تصاویر چهره و تحلیل احساسات)
نویسندگان: تیم پژوهشگران بین‌المللی
سال: ۲۰۲۳
لینک: <https://link.springer.com/article/10.1007/s10489-023-05052-y>
تاریخی که بررسی شد: ۶ اسفند ۱۴۰۳

11-عنوان: الگوریتم‌های شناسایی چهره)
نویسندگان: پژوهشگران بین‌المللی
سال: ۲۰۲۲ یا ۲۰۲۳
لینک: <https://www.mdpi.com/2078-2489/13/6/268>
تاریخی که بررسی شد: ۷ اسفند ۱۴۰۳

12-عنوان: مقاله پیش‌چاپ در زمینه یادگیری عمیق و تشخیص احساسات چهره)
نویسندگان: پژوهشگران دانشگاهی
سال: ۲۰۲۱
لینک: <https://arxiv.org/abs/2105.03588>
تاریخی که بررسی شد: ۷ اسفند ۱۴۰۳

13-عنوان): کاربرد هوش مصنوعی در شناسایی حالات چهره)

نویسندگان: تیم پژوهشگران

سال: ۲۰۲۰

لینک: <https://link.springer.com/article/10.1007/s42452-020-2234-1>

تاریخی که بررسی شد: ۸ اسفند ۱۴۰۳

14-عنوان): مقاله IEEE درباره شناسایی احساسات چهره)

نویسندگان: پژوهشگران بین‌المللی

سال: ۲۰۱۹

لینک: <https://ieeexplore.ieee.org/document/9154121>

تاریخی که بررسی شد: ۸ اسفند ۱۴۰۳

15-عنوان): پیشرفت‌های جدید در پردازش چهره و تحلیل احساسات)

نویسندگان: گروه پژوهشگران IEEE

سال: ۲۰۲۱

لینک: <https://ieeexplore.ieee.org/document/9641578>

تاریخی که بررسی شد: ۹ اسفند ۱۴۰۳

16-عنوان): مقاله پزشکی یا روانشناسی درباره تحلیل حالات چهره و کاربردهای آن)

نویسندگان: پژوهشگران حوزه سلامت یا علوم اعصاب

سال: ۲۰۲۰

لینک: <https://pmc.ncbi.nlm.nih.gov/articles/PMC7599941/>

تاریخی که بررسی شد: ۹ اسفند ۱۴۰۳

17-عنوان): مروری و مجموعه داده‌ها/کدهای مرتبط با تشخیص احساسات چهره)

نویسندگان: مخزن کد و پروژه‌های باز

سال: مرتباً به‌روز می‌شود

لینک: <https://paperswithcode.com/task/facial-emotionrecognition/latest>

تاریخی که بررسی شد: ۱۰ اسفند ۱۴۰۳

Abstract

This study investigates the effectiveness of Convolutional Neural Networks (CNNs) in automated facial emotion recognition. Given the growing importance of emotion detection systems in applications such as human-robot interaction, intelligent marketing, and mental health monitoring, the development of accurate methods in this field is essential.

Research Aim: To identify individuals' emotions through facial image analysis

Research method: This study designed and implemented a Convolutional Neural Network (CNN) architecture, which was trained using the FER-2013 dataset. The model's output was then evaluated and subsequently improved through multiple optimization iterations to enhance its performance.

Findings: After several refinement stages, the model achieved an accuracy exceeding 80%, which represents satisfactory performance given the existing hardware and computational limitations.

Conclusion: Properly designed convolutional neural networks can accurately recognize facial emotions with high precision. This emotion recognition capability has diverse applications across multiple domains.

Keywords: Deep learning, Image processing, Automated emotion recognition



National University of Skill

Gorgan Girls' Branch

A Dissertation Submitted in Partial Fulfillment for the Degree of Bachelor
of Science in Electrical/ICT/Software Engineering

Facial Emotion Recognition

Supervisor:

Komeil Shahvari

By:

Maryam Taheri Emami

June 2025